

Universidad Nacional Autónoma de México  
Maestría en Ciencia e Ingeniería de la Computación  
Preprocesamiento para Ciencia de Datos

Miguel Angel López Sánchez  
Entrega final proyecto Preprocesamiento para Ciencia de Datos  
04 de junio de 2026

## Contenido

|                                                                      |           |
|----------------------------------------------------------------------|-----------|
| <b>Resumen ejecutivo .....</b>                                       | <b>5</b>  |
| <b>1. Marco teórico .....</b>                                        | <b>5</b>  |
| VIH/SIDA .....                                                       | 5         |
| CIE-10 .....                                                         | 6         |
| Calidad de datos .....                                               | 6         |
| Perfilado de datos .....                                             | 6         |
| Limpieza de datos.....                                               | 6         |
| Deduplicación y registro único .....                                 | 7         |
| Integración de datos heterogéneos .....                              | 7         |
| Reducción, discretización y transformación .....                     | 7         |
| Minería de datos y CRISP-DM .....                                    | 8         |
| Consultas heterogéneas, SQL, grafos y representación vectorial ..... | 8         |
| LLM y RAG .....                                                      | 8         |
| <b>2. Problemática detectada .....</b>                               | <b>9</b>  |
| Problemática.....                                                    | 10        |
| Objetivo.....                                                        | 10        |
| Decisiones afectadas por mala calidad de datos.....                  | 10        |
| <b>3. Propuesta de solución .....</b>                                | <b>11</b> |
| Metodología CRISP-DM.....                                            | 11        |
| Preguntas de negocio descriptivas.....                               | 11        |
| Preguntas de negocio predictivas .....                               | 12        |
| Alcance y limitación.....                                            | 12        |
| <b>4. Arquitectura de solución propuesta .....</b>                   | <b>13</b> |
| A) Aplicaciones diversas.....                                        | 13        |
| B) Diversas fuentes de datos .....                                   | 15        |
| 1) CONSULTAS_OTORGADAS_HGM (Hospital General de México) .....        | 15        |
| 2) VIH_RED_COMPLETA (CONAHCYT) .....                                 | 16        |



|                                                                                                         |           |
|---------------------------------------------------------------------------------------------------------|-----------|
| 3) REGISTRO_DEFUNCIONES.....                                                                            | 16        |
| 4) Extra: integración del porcentaje de pruebas reactivas .....                                         | 17        |
| C) Productos utilizados para la solución de cada etapa .....                                            | 17        |
| Integración federada implementada.....                                                                  | 19        |
| <b>5. Esquemas sugeridos a todas y cada una de las fuentes de datos .....</b>                           | <b>20</b> |
| Modelo canónico .....                                                                                   | 20        |
| Métricas canónicas por fuente.....                                                                      | 20        |
| Heterogeneidad.....                                                                                     | 21        |
| Heterogeneidad sintáctica.....                                                                          | 21        |
| Heterogeneidad estructural .....                                                                        | 21        |
| Heterogeneidad de representación.....                                                                   | 22        |
| Heterogeneidad semántica .....                                                                          | 22        |
| Schema matching .....                                                                                   | 22        |
| Schema mapping .....                                                                                    | 23        |
| <b>6. Diagrama que presente las relaciones entre las diferentes fuentes de datos .....</b>              | <b>24</b> |
| <b>7. Procedimiento realizado para la integración de cada fuente de datos.....</b>                      | <b>24</b> |
| Flujo por fuente .....                                                                                  | 25        |
| Tablas base PostgreSQL.....                                                                             | 25        |
| Vistas SQL utilizadas .....                                                                             | 26        |
| Resumen de datos cargados en POSTGRESLQ .....                                                           | 26        |
| <b>8. Procedimiento realizado para el perfilado de datos .....</b>                                      | <b>27</b> |
| 8.1 Archivos perfilados y alcance inicial .....                                                         | 27        |
| 8.2 Preperfilado de HGM .....                                                                           | 27        |
| 8.3 Preperfilado de VIH RED / CONAHCYT .....                                                            | 28        |
| 8.4 Preperfilado de Defunciones .....                                                                   | 30        |
| <b>9. Procedimiento realizado para la limpieza, deduplicación, postperfilado y transformación .....</b> | <b>30</b> |
| 9.1 Limpieza y estandarización.....                                                                     | 30        |
| Estrategias de limpieza implementadas.....                                                              | 31        |
| 9.2 Deduplicación.....                                                                                  | 32        |
| 9.3 Postperfilado.....                                                                                  | 33        |
| 9.4 Transformación y reducción.....                                                                     | 38        |
| 9.5 Comparación del proceso .....                                                                       | 39        |
| <b>10. Procedimiento realizado para el análisis de los datos.....</b>                                   | <b>40</b> |
| Construcción del grafo con NetworkX.....                                                                | 40        |

|                                                                                                                                                                                                        |    |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Construcción del componente vectorial con FAISS .....                                                                                                                                                  | 41 |
| Correlación de indicadores.....                                                                                                                                                                        | 42 |
| Preguntas ejecutadas con el LLM .....                                                                                                                                                                  | 42 |
| Pregunta 1. ¿Cómo cambiaron entre 2019 y 2023 las consultas relacionadas con VIH en Ciudad de México y cómo se compara esa tendencia con la de las defunciones por VIH/SIDA en el mismo periodo? ..... | 42 |
| Pregunta 2. ¿Cómo varió entre 2019 y 2023 la severidad clínica al diagnóstico, medida mediante CD4, y cómo se relaciona temporalmente con los cambios en consultas y defunciones? .....                | 43 |
| Pregunta 3. ¿Cómo cambió entre 2019 y 2023 el porcentaje anual de pruebas reactivas y cómo se comportaron, en ese mismo periodo, las consultas y las defunciones asociadas a VIH/SIDA? .....           | 43 |
| Pregunta 4. ¿Qué diferencias se observan por sexo en consultas, CD4, defunciones y porcentaje de pruebas reactivas a lo largo del periodo 2019-2023? .....                                             | 44 |
| Pregunta 5. ¿Qué diferencias se observan por grupos de edad en consultas, severidad al diagnóstico y defunciones por VIH/SIDA durante el periodo de estudio? .....                                     | 45 |
| Pregunta 6. ¿Cómo se comportaron antes, durante y después de la pandemia las consultas por VIH, los valores de CD4, las defunciones y el porcentaje de pruebas reactivas? .....                        | 46 |
| Pregunta 7. ¿En qué periodos se observa una disminución simultánea o divergente entre consultas, porcentaje de pruebas reactivas y defunciones por VIH/SIDA? .....                                     | 46 |
| Pregunta 8. ¿Cómo cambió la proporción de consultas de primera vez frente a subsecuentes entre 2019 y 2023, y cómo se relaciona con la severidad clínica al diagnóstico y con la mortalidad? .....     | 47 |
| Pregunta 9. ¿Qué patrón temporal muestran los casos con CD4 sugestivo de detección tardía y cómo coincide con los cambios en consultas y defunciones? .....                                            | 48 |
| Pregunta 10. ¿Qué años del periodo 2019-2023 presentan la mayor discrepancia entre porcentaje de pruebas reactivas, demanda de atención y mortalidad por VIH/SIDA? .....                               | 48 |
| Pregunta 11. ¿Qué combinación de cambios en consultas, valores de CD4 y porcentaje de pruebas reactivas permite anticipar periodos con mayor riesgo de incremento en defunciones por VIH/SIDA? .....   | 49 |
| Pregunta 12. ¿La disminución en consultas y en porcentaje de pruebas reactivas permite predecir un aumento posterior en casos con CD4 bajo, consistente con detección tardía? .....                    | 50 |
| Pregunta 13. ¿Qué perfiles de sexo y edad presentan mayor probabilidad de concentrar diagnósticos con mayor severidad clínica en periodos de menor detección aparente? .....                           | 50 |
| Pregunta 14. ¿Qué variaciones en el porcentaje anual de pruebas reactivas permiten anticipar cambios posteriores en la demanda de atención clínica por VIH? .....                                      | 50 |
| Pregunta 15. ¿La combinación de menor actividad en consultas y mayor proporción de casos con CD4 bajo permite predecir periodos con mayor presión clínica futura? .....                                | 51 |
| Pregunta 16. ¿Qué patrones temporales son más consistentes para anticipar si una caída en indicadores observados responde a reducción real del fenómeno o a subdetección? .....                        | 51 |

|                                                                                                                                                                                                    |           |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------|
| Pregunta 17. ¿Qué grupos de edad y sexo presentan mayor probabilidad de mostrar un patrón de detección tardía cuando disminuyen las consultas o cambia la proporción de pruebas reactivas? .....   | 52        |
| Pregunta 18. ¿Los cambios observados en un año del porcentaje de pruebas reactivas permiten anticipar variaciones en las defunciones por VIH/SIDA en el año siguiente?... 52                       |           |
| Pregunta 19. ¿Qué combinación de indicadores temporales permite identificar periodos con mayor probabilidad de desacople entre menor detección aparente y persistencia de desenlaces graves? ..... | 53        |
| Pregunta 20. ¿Qué escenarios temporales de recuperación en consultas y detección serían compatibles con una reducción esperada en severidad al diagnóstico y mortalidad por VIH/SIDA? .....        | 53        |
| <b>11. Visualización de resultados de consultas .....</b>                                                                                                                                          | <b>54</b> |
| <b>12. Conclusiones .....</b>                                                                                                                                                                      | <b>58</b> |
| Sobre el proceso de calidad de datos.....                                                                                                                                                          | 58        |
| Conclusiones del análisis de negocio .....                                                                                                                                                         | 58        |
| <b>Referencias.....</b>                                                                                                                                                                            | <b>59</b> |

## Resumen ejecutivo

Este documento presenta el avance final del proyecto de la clase de Preprocesamiento para Ciencia de Datos, el cual se concentra en indicadores asociados a VIH/SIDA en Ciudad de México durante 2019-2023. Para ello se trabajan tres fuentes de datos principales: consultas del Hospital General de México, muestras y variables clínicas de VIH RED/CONAHCYT, y registros de defunciones. También se integra como insumo complementario el porcentaje anual de pruebas reactivas reportado por CEC. [3][6].

La solución se planteó como una base de datos heterogénea federada. La parte relacional se trabaja en PostgreSQL; la parte de relaciones temporales e indicadores se preparó con NetworkX; la parte textual/vectorial se apoya en TF-IDF, reducción SVD y FAISS; y las consultas de negocio se enrutan mediante un LLM local hacia SQL, grafo o búsqueda vectorial, según corresponda. [21][23].

Se documenta la justificación de fuentes, el modelo canónico, el procedimiento de integración, el perfilado, la limpieza, la deduplicación, la transformación y la evidencia de ejecución del pipeline, junto con la implementación de la propuesta de la técnica RAG para la consulta de las 20 preguntas de negocio con apoyo de un LLM que realiza la consulta e interpreta según corresponda.

## 1. Marco teórico

### VIH/SIDA

La infección por el virus de la inmunodeficiencia humana y el síndrome de inmunodeficiencia adquirida (VIH/SIDA) son un espectro de enfermedades causadas por la infección provocada por el virus de la inmunodeficiencia humana (VIH).

Dicho virus, si no es controlado, destruye el sistema inmune del portador de forma gradual hasta llegar a fase SIDA, en el que el cuerpo es altamente susceptible a infecciones recurrentes como hepatitis, tuberculosis, entre otras.

El VIH/SIDA continúa siendo un problema relevante para sistemas de salud porque requiere un enfoque diagnóstico, seguimiento clínico, tratamiento, vigilancia epidemiológica y mortalidad. Su análisis no depende sólo del número de casos registrados, sino también de la oportunidad con que se detectan, de la calidad del seguimiento y de datos comparables entre fuentes. Los registros clínicos y administrativos permiten abordar de diferentes formas [7].

La severidad clínica puede observarse a partir de indicadores como el conteo de linfocitos CD4, cuyos valores bajos suelen asociarse con mayor deterioro inmunológico y su conteo puede determinar una detección oportuna o tardía. Por otra parte, la carga viral (CV) mide la cantidad de virus presente en la sangre. Es el indicador principal para evaluar la progresión de la infección y la eficacia del tratamiento antirretroviral.

## **CIE-10**

La Clasificación Internacional de Enfermedades, décima revisión, organiza diagnósticos y causas de muerte mediante códigos estandarizados. En VIH/SIDA, es representado en rango B20-B24 y permite homologar sistemas que registran información como atención médica, vigilancia o mortalidad. [9]

Esta codificación reduce ambigüedad semántica entre fuentes de datos, ya que un diagnóstico escrito en texto libre puede variar, mientras que el código CIE-10 no lo hace.

## **Calidad de datos**

La calidad de datos reúne dimensiones que permiten evaluar si una base de datos es adecuada para análisis y toma de decisiones. Entre las dimensiones más relevantes se encuentran completitud, exactitud, consistencia, unicidad, validez, oportunidad y relevancia. Aunque una fuente puede estar completa puede contener duplicados; puede estar estandarizada pero no ser suficiente para responder una pregunta de negocio; o puede tener buena cobertura temporal pero carecer de variables clave. [13], [14], [16]

En salud, la calidad de datos tiene impacto directo sobre interpretación de tendencias, priorización de recursos y intervenciones. Cuando los datos de consultas, pruebas, laboratorio y defunciones no se integran con reglas claras, se pueden producir lecturas sesgadas: aparentes reducciones, incrementos artificiales o comparaciones entre periodos que no consideran cambios de registro, cobertura o acceso a servicios. [17]

## **Perfilado de datos**

El perfilado permite observar estructura, tipos de dato, valores faltantes, cardinalidad, dominios, rangos y patrones. Esta etapa funciona como diagnóstico inicial de una fuente: permite ubicar columnas críticas, variables constantes, categorías raras, valores extremos, errores de formato y diferencias entre lo esperado y lo registrado.

Además de describir la base, el perfilado orienta decisiones posteriores. Un campo con alta cardinalidad puede requerir normalización; una variable con muchos nulos puede necesitar imputación, exclusión o análisis de impacto; y una fecha con formatos inconsistentes puede afectar integración temporal. En bases heterogéneas, el perfilado también permite comparar qué variables son realmente compatibles entre fuentes.

## **Limpieza de datos**

La limpieza de datos agrupa actividades orientadas a corregir errores, reducir ruido y preparar la información para análisis. Incluye pero no se limita a estandarización de formatos, normalización de categorías, tratamiento de valores faltantes, corrección de tipos de dato, filtrado de registros y generación de variables derivadas.

La trazabilidad de estos cambios es importante porque permite explicar qué se modificó, qué se eliminó y qué supuestos se tomaron, además, no se busca alterar la información, sino hacer que los registros sean más consistentes y utilizables. [15], [17]

### **Deduplicación y registro único**

La deduplicación atiende registros que representan el mismo evento o entidad, pero aparecen más de una vez por errores de captura, consolidación, carga o integración. Los duplicados pueden inflar conteos, distorsionar tasas y afectar cualquier análisis posterior. La detección puede usar coincidencias exactas, comparaciones aproximadas, similitud de fechas, variables demográficas y reglas de bloqueo para reducir el espacio de comparación. [18]

Cuando se identifican posibles duplicados, se requiere una regla de conservación que define qué registro permanece y cuáles se consideran redundantes. En algunos casos se conserva el registro más completo; en otros, el primero, el más reciente o aquel con identificador mínimo. La decisión debe quedar documentada para que el proceso sea reproducible y para evitar que la limpieza se convierta en una eliminación arbitraria.

### **Integración de datos heterogéneos**

La integración de datos heterogéneos busca relacionar fuentes con estructuras, granularidades y significados distintos. Las diferencias pueden ser sintácticas, cuando los nombres o formatos cambian; estructurales, cuando los campos no existen en todas las fuentes; semánticas, cuando una variable tiene significados diferentes; o de representación, cuando un mismo concepto se expresa con códigos, texto o categorías distintas.

El mapeo de esquemas permite establecer correspondencias entre variables. Una vez identificadas las equivalencias, las fuentes pueden conectarse mediante llaves comunes, variables agregadas o entidades compartidas. En escenarios donde no existe identificador individual común, la integración suele apoyarse en dimensiones temporales, demográficas o geográficas para generar una vista federada sin forzar una unión artificial de registros que no corresponden al mismo individuo.

### **Reducción, discretización y transformación**

La transformación prepara los datos para consulta, análisis o modelado. Incluye conversión de fechas, escalamiento de variables numéricas, codificación de categorías, creación de indicadores, agregación temporal y construcción de variables derivadas. Por otra parte, la discretización agrupa valores continuos en intervalos útiles para análisis, como rangos de edad, periodos temporales o grupos de severidad. [2]

La reducción elimina variables redundantes, irrelevantes o de baja utilidad analítica, siempre que no se comprometa la trazabilidad. En proyectos de calidad de datos, estas operaciones ayudan a construir una base más estable para consultas y visualizaciones.

## **Minería de datos y CRISP-DM**

La minería de datos es un proceso que permite identificar patrones, asociaciones, agrupamientos y relaciones útiles para interpretar un fenómeno y puede tener enfoque descriptivo, cuando resume comportamiento observado, o predictivo, cuando busca anticipar una variable o escenario futuro a partir de datos disponibles. En ambos casos, la calidad del resultado depende de la preparación previa de los datos. [10]

La metodología CRISP-DM organiza el trabajo en etapas: entendimiento del negocio, entendimiento de los datos, preparación, modelado, evaluación y despliegue. Esta metodología ayuda a conectar preguntas de negocio con operaciones técnicas, evitando que el análisis se reduzca a ejecución de código sin propósito. También permite separar lo que corresponde al diagnóstico de datos, lo que corresponde a preparación y lo que forma parte del análisis posterior. [10], [11]

## **Consultas heterogéneas, SQL, grafos y representación vectorial**

Las consultas heterogéneas combinan distintas formas de acceso a datos. SQL permite trabajar con tablas, filtros, agregaciones y relaciones estructuradas. Los grafos representan nodos y aristas, lo que facilita observar relaciones entre periodos, indicadores, fuentes o entidades. Las representaciones vectoriales permiten recuperar documentos o descripciones por similitud semántica, sobre todo cuando existe texto clínico, diagnóstico o descriptivo que puede que no siempre coincida entre sí, pero tengan características en común.

En una arquitectura heterogénea, cada tipo de consulta responde mejor a ciertos objetos. Las tablas son adecuadas para conteos, promedios y agregaciones; los grafos para relaciones y trayectorias entre objetos; y los vectores para recuperación semántica de contenido textual.

En este proyecto se usan herramientas como PostgreSQL, NetworkX y FAISS que cubren estas capas desde perspectivas distintas: relacional, red y búsqueda vectorial. [21], [22], [23]

## **LLM y RAG**

Los modelos de lenguaje permiten recibir preguntas en lenguaje natural y transformarlas en instrucciones más cercanas a una consulta técnica. En un esquema de recuperación aumentada (RAG), el modelo no responde sólo desde su conocimiento interno, sino que se apoya en información recuperada de una base, documento, índice o sistema externo. Esto reduce dependencia de memoria paramétrica y permite conectar lenguaje natural con datos disponibles. [12]

El uso de un LLM en un sistema de consultas requiere mucho control: la pregunta debe clasificarse, enviarse al backend adecuado, ejecutarse contra la fuente correspondiente y devolver una respuesta verificable.



## 2. Problemática detectada

Pregunta central: En la atención al VIH, ¿Qué cambios se observaron a lo largo del tiempo en consultas, resultados de laboratorio con CD4, defunciones y porcentaje de pruebas reactivas por año, y si esos cambios son consistentes entre sí para interpretar si la caída en detecciones durante la pandemia reflejó menor transmisión o retraso diagnóstico?




Figura 1 - Conteo de pruebas reactivas realizadas por la CEC por año




Figura 2 - Porcentaje de pruebas reactivas observadas por CEC

## Problemática

En la atención del VIH en CDMX, muchas decisiones dependen de datos que provienen de fuentes distintas: consultas, laboratorio, defunciones y pruebas. El problema es que esas fuentes no siempre se pueden comparar de forma directa. Si se analizan por separado, pueden dar una lectura incompleta del problema. [6][8].

Esto afecta la interpretación porque:

- No siempre se tiene claro cuántas pruebas se realizaron, cuántas fueron reactivas y qué tan amplia fue la cobertura.
- Las bases pueden concentrarse en personas que ya llegaron a consulta o laboratorio, dejando fuera casos no detectados.
- Comparar prepandemia, pandemia y postpandemia puede ser difícil si cambió el registro, la atención o el acceso a pruebas.
- Una baja en consultas o diagnósticos no necesariamente significa menos VIH; también puede significar menor detección.
- Las decisiones de recursos pueden apoyarse en tendencias incompletas.

Por eso, la problemática del proyecto no es sólo contar casos de VIH. El objetivo es revisar si los cambios observados en consultas, CD4, defunciones y pruebas reactivas apuntan a un cambio real del fenómeno, o si reflejan problemas de calidad, integración y comparabilidad de los datos. [6][8].

## Objetivo

Analizar el comportamiento temporal de indicadores asociados al VIH/SIDA en Ciudad de México entre 2019 y 2023, a partir de información de consultas, variables de laboratorio vinculadas al diagnóstico, defunciones y porcentaje anual de pruebas reactivas, con el fin de evaluar si las variaciones observadas antes, durante y después de la pandemia son consistentes con una disminución real del problema o con un patrón de detección tardía. [3][9].

## Decisiones afectadas por mala calidad de datos

- Evaluar de forma equivocada si hubo reducción real del problema o disminución en detección.
- Sobreestimar o subestimar positividad al no contar con denominadores comparables.
- Interpretar de forma incorrecta la relación entre atención clínica, severidad al diagnóstico y mortalidad.
- Comparar periodos sin controlar cobertura, tipo de prueba, registro o fuente.
- Priorizar recursos, personal o campañas con base en tendencias incompletas.
- Formular conclusiones epidemiológicas sin evidencia suficiente.

### 3. Propuesta de solución

#### Metodología CRISP-DM

La metodología del proyecto se organizó con base en **CRISP-DM**:

Primero se definió la problemática de negocio: interpretar si los cambios observados en indicadores de VIH en CDMX corresponden a cambios reales del fenómeno o a problemas de observación derivados de fuentes incompletas, no integradas o no comparables. Después se seleccionaron fuentes públicas relacionadas con atención clínica, laboratorio, defunciones y pruebas reactivas. [10], [11].

A partir de esas fuentes se construyó un flujo de trabajo con etapas de fusión, filtrado a CDMX, perfilado inicial, limpieza, estandarización, deduplicación, perfilado posterior, transformación e integración. El resultado fue una base de trabajo heterogénea, organizada para consultas relacionales, análisis por grafo y recuperación vectorial de información textual.

La integración no es a nivel persona, ya que las fuentes no contienen un ID común en registros individuales. Por esa razón, la integración se realizó a nivel agregado, usando mes, sexo, grupo de edad y periodo de análisis como ejes comunes. Así se evita asumir correspondencias individuales que no existen en los datos y permite comparar tendencias temporales.

Con este diseño, el proyecto no busca reconstruir trayectorias clínicas individuales. Su objetivo es generar una vista federada y comparable de indicadores para analizar cambios temporales, diferencias entre grupos y posibles señales de subregistro y detección tardía

#### Preguntas de negocio descriptivas

- 1) ¿Cómo cambiaron entre 2019 y 2023 las consultas relacionadas con VIH en Ciudad de México y cómo se compara esa tendencia con la de las defunciones por VIH/SIDA en el mismo periodo?
- 2) ¿Cómo varió entre 2019 y 2023 la severidad clínica al diagnóstico, medida mediante CD4, y cómo se relaciona temporalmente con los cambios en consultas y defunciones?
- 3) ¿Cómo cambió entre 2019 y 2023 el porcentaje anual de pruebas reactivas y cómo se comportaron, en ese mismo periodo, las consultas y las defunciones asociadas a VIH/SIDA?
- 4) ¿Qué diferencias se observan por sexo en consultas, CD4, defunciones y porcentaje de pruebas reactivas a lo largo del periodo 2019-2023?
- 5) ¿Qué diferencias se observan por grupos de edad en consultas, severidad al diagnóstico y defunciones por VIH/SIDA durante el periodo de estudio?
- 6) ¿Cómo se comportaron antes, durante y después de la pandemia las consultas por VIH, los valores de CD4, las defunciones y el porcentaje de pruebas reactivas?
- 7) ¿En qué periodos se observa una disminución simultánea o divergente entre consultas, porcentaje de pruebas reactivas y defunciones por VIH/SIDA?
- 8) ¿Cómo cambió la proporción de consultas de primera vez frente a subsecuentes entre 2019 y 2023, y cómo se relaciona con la severidad clínica al diagnóstico y con la mortalidad?

- 9) ¿Qué patrón temporal muestran los casos con CD4 sugestivo de detección tardía y cómo coincide con los cambios en consultas y defunciones?
- 10) ¿Qué años del periodo 2019-2023 presentan la mayor discrepancia entre porcentaje de pruebas reactivas, demanda de atención y mortalidad por VIH/SIDA?

### Preguntas de negocio predictivas

- 11) ¿Qué combinación de cambios en consultas, valores de CD4 y porcentaje de pruebas reactivas permite anticipar periodos con mayor riesgo de incremento en defunciones por VIH/SIDA?
- 12) ¿La disminución en consultas y en porcentaje de pruebas reactivas permite predecir un aumento posterior en casos con CD4 bajo, consistente con detección tardía?
- 13) ¿Qué perfiles de sexo y edad presentan mayor probabilidad de concentrar diagnósticos con mayor severidad clínica en periodos de menor detección aparente?
- 14) ¿Qué variaciones en el porcentaje anual de pruebas reactivas permiten anticipar cambios posteriores en la demanda de atención clínica por VIH?
- 15) ¿La combinación de menor actividad en consultas y mayor proporción de casos con CD4 bajo permite predecir periodos con mayor presión clínica futura?
- 16) ¿Qué patrones temporales son más consistentes para anticipar si una caída en indicadores observados responde a reducción real del fenómeno o a subdetección?
- 17) ¿Qué grupos de edad y sexo presentan mayor probabilidad de mostrar un patrón de detección tardía cuando disminuyen las consultas o cambia la proporción de pruebas reactivas?
- 18) ¿Los cambios observados en un año del porcentaje de pruebas reactivas permiten anticipar variaciones en las defunciones por VIH/SIDA en el año siguiente?
- 19) ¿Qué combinación de indicadores temporales permite identificar periodos con mayor probabilidad de desacople entre menor detección aparente y persistencia de desenlaces graves?
- 20) ¿Qué escenarios temporales de recuperación en consultas y detección serían compatibles con una reducción esperada en severidad al diagnóstico y mortalidad por VIH/SIDA?

### Alcance y limitación

El sistema federado se limita a Ciudad de México. La integración se realiza por mes, sexo y grupo de edad. Esta escala permite comparar consultas, resultados de laboratorio, defunciones e indicadores de pruebas reactivas sin asumir que los registros pertenecen a las mismas personas.

El análisis trabaja con datos agregados. Por ello, no se modela causalidad clínica individual, no reconstruye trayectorias de pacientes y no sustituye procesos de vigilancia epidemiológica. Su utilidad está en ordenar distintas fuentes, mejorar su calidad y comparar tendencias entre atención, laboratorio, mortalidad y pruebas.

Por otra parte, a pesar de que al inicio del proyecto se solicitaron 10 preguntas predictivas, en este proyecto no se implementó un modelo supervisado, prescriptivo o de pronóstico numérico que estime probabilidades futuras o escenarios.

El LLM no produce predicciones clínicas ni sustituye un modelo de aprendizaje automático entrenado para predecir o prescribir. Su papel es solo traducir preguntas en lenguaje natural hacia consultas SQL, consultas sobre grafo o búsqueda vectorial, recuperar resultados y organizarlos para el usuario. Cuando una pregunta requiere predicción formal, el sistema responde con evidencia descriptiva disponible y exploratoria.

## 4. Arquitectura de solución propuesta

La arquitectura de la solución se diseñó como un proceso secuencial para preparar, integrar y consultar fuentes heterogéneas relacionadas con VIH/SIDA en Ciudad de México. El proceso parte de archivos CSV descargados desde portales públicos y termina en una base relacional con vistas SQL, un grafo de indicadores, un corpus vectorial y respuestas estructuradas a las preguntas de negocio mediante un LLM local.

### A) Aplicaciones diversas

Para el proyecto se usaron herramientas de descarga, inspección, procesamiento, integración, visualización y consulta. Su función principal fue construir un flujo reproducible y dejar evidencia de cada etapa del preprocesamiento y la integración.

| Herramienta o producto                | Uso dentro del proyecto                                                                         | Resultado dentro de la solución                                                  |
|---------------------------------------|-------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| Internet / portales de datos abiertos | Descarga de las fuentes públicas usadas en el proyecto.                                         | Archivos CSV originales de HGM, VIH RED/CONAHCYT y Defunciones.                  |
| Excel                                 | Inspección visual inicial, validación de encabezados y guardado en CSV delimitado por comas.    | Revisión de estructura y corrección puntual de archivos antes de combinarlos.    |
| Notepad++                             | Revisión de archivos en texto plano, encabezados, separadores y contenido real del CSV.         | Confirmación de que los archivos se leían como texto separado por comas.         |
| Python / pandas                       | Lectura, combinación, filtrado, limpieza, transformación y exportación de archivos intermedios. | CSV consolidados, limpios, sin duplicados y transformados.                       |
| numpy / re / unicodedata              | Cálculos auxiliares, expresiones regulares y normalización de texto.                            | Homologación de variables, detección de patrones y limpieza de cadenas.          |
| recordlinkage                         | Detección de posibles duplicados mediante blocking y comparación de atributos.                  | Archivos por fuente con registros redundantes reducidos.                         |
| matplotlib                            | Gráficas de perfilado, análisis descriptivo y evidencias visuales.                              | Histogramas, diagramas de caja, correlaciones, agrupamientos y salidas PNG.      |
| PostgreSQL / SQL                      | Carga relacional, creación de tablas base y vistas federadas.                                   | Tablas de fuentes, vistas mensuales, vistas por sexo y vistas por grupo de edad. |
| NetworkX                              | Construcción de grafo dirigido con meses, periodos e indicadores.                               | Grafo en formato PKL, JSON, PNG y archivos CSV de nodos o cambios mensuales.     |
| scikit-learn + FAISS                  | Vectorización de diagnósticos HGM y búsqueda por similitud textual.                             | Índice FAISS, corpus, metadatos JSON/CSV y modelos de vectorización.             |
| LLM local / llama-cpp-python          | Enrutamiento de preguntas hacia SQL, grafo o búsqueda vectorial.                                | Respuestas estructuradas para las veinte preguntas de negocio.                   |
| pgAdmin / PowerShell                  | Ejecución, validación y evidencia del pipeline.                                                 | Capturas de tablas, vistas, salidas de consola y archivos generados.             |

| Herramienta o producto | Uso dentro del proyecto                             | Resultado dentro de la solución                  |
|------------------------|-----------------------------------------------------|--------------------------------------------------|
| Draw.io                | Elaboración del diagrama de relación entre fuentes. | Diagrama de arquitectura e integración de datos. |

Tabla 1 - Herramientas utilizadas




Figura 3 - Guardado de archivo como CSV delimitado por comas

|    | CONSULTAS_OTORGADAS_2020.csv                                                             |
|----|------------------------------------------------------------------------------------------|
| 1  | FECHA, TIPO_CONSULTA, PROCEDENCIA, SEXO, EDAD, UNIDAD, ESPECIALIDAD, CODIGO, DESCRIPCION |
| 2  | 22/07/2020, PRIMERA VEZ, EDO. DE MEXICO, MASCULINO, 61, NUTRICION CLINICA, NUTRICION     |
| 3  | 22/07/2020, PRIMERA VEZ, EDO. DE MEXICO, FEMENINO, 35, NUTRICION CLINICA, NUTRICION      |
| 4  | 22/07/2020, SUBSECUENTE, EDO. DE MEXICO, MASCULINO, 50, NUTRICION CLINICA, NUTRICION     |
| 5  | 22/07/2020, SUBSECUENTE, EDO. DE MEXICO, FEMENINO, 48, NUTRICION CLINICA, NUTRICION      |
| 6  | 11/02/2020, SUBSECUENTE, PUEBLA, FEMENINO, 50, CONSULTA EXTERNA CENTRAL 401, MEDICINA    |
| 7  | 11/02/2020, PRIMERA VEZ, EDO. DE MEXICO, FEMENINO, 21, CONSULTA EXTERNA CENTRAL 401      |
| 8  | 11/02/2020, PRIMERA VEZ, CIUDAD DE MEXICO, MASCULINO, 19, CONSULTA EXTERNA CENTRAL       |
| 9  | 11/02/2020, SUBSECUENTE, CIUDAD DE MEXICO, FEMENINO, 82, CONSULTA EXTERNA CENTRAL        |
| 10 | 11/02/2020, SUBSECUENTE, EDO. DE MEXICO, MASCULINO, 46, CONSULTA EXTERNA CENTRAL         |
| 11 | 11/02/2020, SUBSECUENTE, EDO. DE MEXICO, FEMENINO, 33, CONSULTA EXTERNA CENTRAL          |
| 12 | 11/02/2020, SUBSECUENTE, EDO. DE MEXICO, FEMENINO, 25, CONSULTA EXTERNA CENTRAL          |
| 13 | 11/02/2020, PRIMERA VEZ, CIUDAD DE MEXICO, MASCULINO, 60, CONSULTA EXTERNA CENTRAL       |
| 14 | 11/02/2020, SUBSECUENTE, EDO. DE MEXICO, FEMENINO, 24, CONSULTA EXTERNA CENTRAL          |
| 15 | 11/02/2020, SUBSECUENTE, EDO. DE MEXICO, FEMENINO, 64, CONSULTA EXTERNA CENTRAL          |
| 16 | 11/02/2020, PRIMERA VEZ, CIUDAD DE MEXICO, FEMENINO, 63, CONSULTA EXTERNA CENTRAL        |

Figura 4- Revisión de estructura CSV en texto plano

```

1 # Practica / apoyo para perfilado de bases CSV
2 # Nombre: Miguel Angel Lopez Sanchez
3 # Perfilado general reutilizable para bases del proyecto
4
5 import pandas as pd
6 import numpy as np
7 import matplotlib.pyplot as plt
8 import recordlinkage
9
10 from code_python.herramientas.reporte_consola import titulo, seccion, metrica,
11
12 pd.set_option('display.max_rows', None)
13 pd.set_option('display.max_columns', None)
14 pd.set_option("display.expand_frame_repr", False)
15

```

Figura 5 - Muestra de librerías utilizadas en el proyecto

## B) Diversas fuentes de datos

Las fuentes seleccionadas cubren diferentes partes del fenómeno: atención clínica, vigilancia de laboratorio, mortalidad e información auxiliar sobre pruebas reactivas de VIH. Todas se trabajaron dentro de Ciudad de México. Las tres fuentes principales se procesaron a nivel de registro; CEC se incorporó como tabla auxiliar agregada.

| Fuente                  | Cobertura usada            | Volumen usado                                                                             | Variables principales                                                                                |
|-------------------------|----------------------------|-------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| Consultas otorgadas HGM | 2019-2023                  | 956,663 registros filtrados a CDMX; 945,424 registros después de limpieza y deduplicación | FECHA, TIPO_CONSULTA, SEXO, EDAD, ESPECIALIDAD, CODIGO, DESCRIPCION_DIAGNOSTICO, VIH_FLAG            |
| VIH RED / CONAHCYT      | 17/07/2019 a 14/12/2023    | 9,221 registros filtrados a CDMX; 9,019 registros después de limpieza y deduplicación     | ID_MUESTRA, FECHA_TOMA, SEXO, GENERO, EDAD, MUNICIPIO, SEGURIDAD_SOCIAL, CV, CD4_A, VIH_TARDIO_FLAG  |
| Registro de defunciones | 2019-2023                  | 498,110 registros filtrados a CDMX; 490,190 registros después de limpieza y deduplicación | FECHA_OCURREN, FECHA_ANIO_MES, CAUSA_DEF, SEXO, EDAD, ENT_OCURREN, MUN_OCURREN, DERECHOHAB, VIH_FLAG |
| CEC - pruebas reactivas | Indicador anual disponible | Tabla pequeña de 3 registros y alrededor de 6 columnas                                    | Año, pruebas reactivas y porcentajes de reactividad por grupo o programa                             |

Tabla 2 - Resumen de las bases de datos utilizadas

### 1) CONSULTAS\_OTORGADAS\_HGM (Hospital General de México)

La base de consultas se incorpora porque permite observar la demanda de atención clínica asociada al VIH/SIDA a lo largo del tiempo. Su utilidad analítica radica en que aproxima el uso de servicios de salud y sus variaciones durante el periodo de estudio, lo que permite identificar posibles cambios en acceso, continuidad o presión asistencial.

Esta fuente aporta la dimensión de atención clínica del fenómeno y permite contrastar si las variaciones observadas en otros indicadores se acompañan, o no, de cambios en servicios médicos.



Contiene registros de consultas otorgadas con fecha completa, sexo, edad, especialidad y código diagnóstico. La variable TIPO\_CONSULTA permite distinguir primera vez de subsecuente, lo que abre la posibilidad de analizar cambios en patrones de demanda.

La variable PROCEDENCIA incluye la categoría Ciudad de México, lo que habilita el filtrado geográfico. Para su integración, los archivos anuales se descargaron por separado, se homologaron encabezados para permitir su combinación y posteriormente se fusionaron en un solo archivo filtrado a CDMX.

## **2) VIH\_RED\_COMPLETA (CONAHCYT)**

Esta base aporta información clínica relevante para caracterizar el momento del diagnóstico, especialmente mediante el valor de cd4\_a como indicador de severidad inmunológica. Permite aproximarse a la detección tardía, ya que concentraciones bajas de CD4 pueden asociarse con diagnósticos en etapas más avanzadas de la infección. Su función dentro del análisis es diferenciar si los cambios observados en el tiempo reflejan una modificación real del comportamiento del VIH o si, por el contrario, están acompañados de un agravamiento en las condiciones clínicas al momento de la identificación de los pacientes.

Contiene información de muestras relacionadas con vigilancia de VIH en CDMX, junto con variables clínicas como cd4\_a y carga viral (cv), además de variables demográficas. La cobertura inicia a mediados de 2019 y termina a finales de 2023, por lo que el análisis mensual debe considerar meses faltantes al inicio o al final del periodo.

A diferencia de HGM y Defunciones, no requirió combinación anual previa; el procesamiento consistió en filtrar directamente los registros correspondientes a Ciudad de México y preparar el archivo para su perfilado, limpieza y deduplicación.

## **3) REGISTRO\_DEFUNCIONES**

La base de defunciones se incorpora porque representa el desenlace final del proceso de atención y permite evaluar si los cambios observados en detección y atención clínica se reflejan en la mortalidad asociada al VIH/SIDA. Aunque esta fuente no informa sobre tamizaje ni diagnóstico inicial, sí aporta una medida de resultado que permite contrastar la evolución del problema desde la perspectiva más crítica.

Complementa la lectura de consultas y laboratorio, evitando interpretaciones parciales cuando los indicadores intermedios no coinciden con los resultados finales en salud.

Contiene registros de defunciones con fecha, sexo y variables necesarias para derivar edad, además de CAUSA\_DEF como código CIE. Para su preparación, los archivos anuales se descargaron por separado, se combinaron en un solo archivo y posteriormente se filtraron a Ciudad de México mediante la entidad de ocurrencia (ENT\_OCURRE). El objetivo analítico es construir una serie mensual de defunciones atribuibles a VIH/SIDA dentro del rango CIE-10 B20 a B24.



#### 4) Extra: integración del porcentaje de pruebas reactivas

La integración del porcentaje anual de pruebas reactivas aporta un indicador relacionado con la detección durante el periodo de estudio. Su inclusión permite contextualizar mejor los cambios observados en consultas, CD4 y defunciones, ya que una disminución en casos identificados no puede interpretarse adecuadamente sin considerar el comportamiento de las pruebas realizadas y su proporción de reactividad.

Este porcentaje funciona como un insumo complementario para la interpretación temporal de resultados. Su valor no está en sustituir a las tres bases operativas principales, sino en añadir una referencia adicional para distinguir entre una posible reducción real del problema y una disminución aparente asociada a cambios en tamizaje o cambios en diagnóstico.

#### C) Productos utilizados para la solución de cada etapa

La arquitectura se implementó como un flujo secuencial. Cada etapa genera productos intermedios que sirven como insumo de la siguiente. Esto permite revisar el proceso desde los archivos originales hasta las respuestas generadas por el sistema de consulta heterogénea.

| Etapa                                   | Qué se hizo                                                                                                 | Producto generado                                                                                                  | Scripts                                                                                                                                                 |
|-----------------------------------------|-------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>1. Descarga e inspección inicial</b> | Archivos CSV originales descargados desde fuentes abiertas; revisión con Excel y Notepad++.                 | CSV fuente por año o por base.                                                                                     | Excel, Notepad++, exploración manual de CSV.                                                                                                            |
| <b>2. Fusión y filtrado CDMX</b>        | Combinación de archivos anuales en HGM y Defunciones; filtrado territorial en las tres fuentes principales. | consultas_HGM_cdmx_2019_2023.csv; vih_red_completa_cdmx_2019_2023.csv; defunciones_registradas_cdmx_2019_2023.csv. | combinador_consultas_hospital.py, combinador_vih.py, combinador_defunciones.py                                                                          |
| <b>3. Preperfilado</b>                  | Revisión inicial de filas, columnas, completitud, nulos, cardinalidad, distribuciones y valores extremos.   | Salida de consola, tablas de perfilado y visualizaciones exploratorias.                                            | perfiar_vih.py, perfiar_defunciones.py, perfiar_consultas_hospital.py, perfilador.py                                                                    |
| <b>4. Limpieza y estandarización</b>    | Normalización de fechas, sexo, edad, municipios, texto diagnóstico, códigos CIE y variables derivadas.      | CSV con terminación _limpio.csv.                                                                                   | limpieza_estandarizacion_vih.py, limpieza_estandarizacion_consultas_hospital.py, limpieza_estandarizacion_defunciones.py                                |
| <b>5. Deduplicación</b>                 | Aplicación de blocking y comparación por fuente para reducir registros redundantes.                         | CSV con terminación _limpio_sin_duplicados.csv.                                                                    | deduplicar_vih.py, deduplicar_consultas_hospital.py, deduplicar_defunciones.py, herramientas/deduplicador.py                                            |
| <b>6. Postperfilado</b>                 | Perfilado posterior sobre archivos limpios y deduplicados para revisar la estructura final.                 | Tablas de postperfilado y salida de consola.                                                                       | perfiar_vih_limpio_sin_duplicados.py, perfiar_defunciones_limpio_sin_duplicados.py, perfiar_consultas_hospital_limpio_sin_duplicados.py, perfilador.py. |
| <b>7. Transformación y reducción</b>    | Creación de variables numéricas, temporales y de integración; reducción de atributos redundantes.           | CSV con terminación _transformado.csv.                                                                             | Transformacion_y_reduccion_de_vih.py, Transformacion_y_reduccion_de_consultas_hospital.py, Transformacion_y_reduccion_de_defunciones.py                 |
| <b>8. Carga relacional</b>              | Carga de archivos transformados en PostgreSQL.                                                              | Tablas consultas_hgm, vih_red, defunciones y pruebas_reactivas_cec.                                                | cargar_sql.py, 00_crear_tablas_reproducible.sql, PostgreSQL.                                                                                            |
| <b>9. Integración por vistas SQL</b>    | Creación de vistas por mes, sexo y grupo de edad                                                            | Vistas mensuales integradas y vistas por sexo/grupo de edad.                                                       | 01_crear_vistas_reproducible.sql.                                                                                                                       |

|                                    |                                                                                           |                                                                  |                                                  |
|------------------------------------|-------------------------------------------------------------------------------------------|------------------------------------------------------------------|--------------------------------------------------|
|                                    | usando FECHA_ORDEN_MES como eje común.                                                    |                                                                  |                                                  |
| <b>10. Análisis descriptivo</b>    | Cálculo de resúmenes, correlaciones, agrupamientos y salidas analíticas.                  | CSV, JSON y PNG en salidas_analisis.                             | analisis_mineria_descriptiva.py                  |
| <b>11. Grafo NetworkX</b>          | Construcción de grafo dirigido con meses, periodos e indicadores.                         | grafo_metricas_mensuales.pkl, .json, .png y CSV de nodos/deltas. | crear_grafo_networkx.py                          |
| <b>12. Corpus vectorial FAISS</b>  | Construcción de corpus textual/vectorial con diagnósticos HGM por CIE y mes.              | hgm_cie_mensual.faiss, JSON, JSONL, CSV, JOBLIB y PNG.           | crear_corpus_vectorial.py.                       |
| <b>13. Consultas con LLM local</b> | Procesamiento de veinte preguntas de negocio y enrutamiento hacia SQL, grafo o vectorial. | respuestas_20_preguntas.json.                                    | main.py, consultas_llm.py, interpretador_llm.py. |

Tabla 3 - Etapas del proyecto

El flujo inició con los archivos originales de cada fuente. Primero se fusionaron los archivos por año y se filtraron a Ciudad de México. Después se realizó un preperfilado para conocer número de registros, columnas, valores nulos, cardinalidad, distribuciones y posibles problemas de calidad.

Con base en ese diagnóstico se aplicaron reglas de limpieza y estandarización. Se normalizaron fechas, sexo, edad, grupo de edad, códigos CIE, CD4 y variables necesarias para el análisis. Después se aplicó deduplicación por fuente, usando columnas de bloqueo y comparaciones exactas, numéricas y de fecha. El resultado fueron archivos sin duplicados, que se perfilaron de nuevo para verificar la estructura posterior.

Luego se aplicó transformación y reducción. En esta etapa se generaron variables temporales y numéricas, entre ellas FECHA\_ORDEN\_MES, que permitió integrar las fuentes a nivel mensual. Los archivos transformados se cargaron en PostgreSQL, donde se crearon tablas base y vistas SQL.

A partir de las vistas se generaron tres capas de consulta. La primera fue relacional, basada en SQL. La segunda fue de grafo, construida con NetworkX para representar meses, periodos e indicadores. La tercera fue vectorial, construida con scikit-learn y FAISS a partir de diagnósticos HGM. Sobre esas capas se ejecutó un LLM local que recibió las 20 preguntas de negocio, eligió el backend correspondiente y devolvió respuestas estructuradas.

```

64 print("Inicio del flujo del proyecto.")
65
66 combinar_vih()
67 combinar_defunciones()
68 combinar_consultas_hospital()
69
70 runpy.run_path(str(ruta_proyecto / "code_python" / "perfilar_vih
71 runpy.run_path(str(ruta_proyecto / "code_python" / "perfilar_def
72 runpy.run_path(str(ruta_proyecto / "code_python" / "perfilar_con
73
74 limpieza_estandarizacion_vih()
75 limpieza_estandarizacion_consultas_hospital()
76 limpieza_estandarizacion_defunciones()
77
78 deduplicar_vih()
79 deduplicar_consultas_hospital()
80 deduplicar_defunciones()
81
82 runpy.run_path(str(ruta_proyecto / "code_python" / "perfilar_vih
83 runpy.run_path(str(ruta_proyecto / "code_python" / "perfilar_def
84 runpy.run_path(str(ruta_proyecto / "code_python" / "perfilar_con
85
86 transformar_reducir_vih()
87 transformar_reducir_consultas_hospital()
88 transformar_reducir_defunciones()
89
90 cargar_a_sql()
91
92 ejecutar_analisis_mineria_descriptiva()
93
94 crear_grafo_metricas_mensuales()
95 crear_corpus_vectorial_hgm_faiss()
96
97 ruta_salidas.mkdir(exist_ok=True)
98 ruta_respuestas.write_text("[ ]", encoding="utf-8")

```

Figura 6 - Flujo de trabajo implementado en código

## Integración federada implementada

La integración se implementó mediante vistas SQL, no mediante una tabla física única. Las tablas base conservan el origen de cada fuente y las vistas integradas permiten compararlas con el eje común FECHA\_ORDEN\_MES. Esta variable se derivó de año y mes para conectar los registros en una escala mensual.

Las vistas principales fueron:

| Vista                        | Función                                                       |
|------------------------------|---------------------------------------------------------------|
| vw_calendario_mensual        | Define el eje temporal mensual de 2019 a 2023.                |
| vw_pruebas_reactivas_mensual | Lleva el indicador anual CEC al calendario mensual.           |
| vw_consultas_hgm_mensual     | Agrega consultas y diagnósticos HGM por mes.                  |
| vw_vih_red_mensual           | Agrega indicadores de laboratorio y detección tardía por mes. |
| vw_defunciones_mensual       | Agrega defunciones y marca VIH por mes.                       |

|                                             |                                                            |
|---------------------------------------------|------------------------------------------------------------|
| vw_hgm_vector_cie_mensual                   | Prepara diagnósticos HGM para el corpus textual/vectorial. |
| vw_metricas_mensuales_integradas            | Integra métricas generales por mes.                        |
| vw_metricas_mensuales_integradas_sexo       | Integra métricas por mes y sexo.                           |
| vw_metricas_mensuales_integradas_grupo_edad | Integra métricas por mes y grupo de edad.                  |

Se decidió utilizar vistas porque esta organización permitió conservar la independencia de cada fuente y, al mismo tiempo, generar consultas integradas sobre indicadores comparables.

El grafo NetworkX y el índice FAISS se construyeron sobre salidas ya integradas o preparadas desde PostgreSQL. El grafo representó meses, periodos e indicadores agregados; FAISS permitió consultar diagnósticos HGM mediante similitud textual. Finalmente, el LLM local recibió las veinte preguntas de negocio y devolvió respuestas estructuradas con base en los componentes relacional, de grafo y vectorial.

## 5. Esquemas sugeridos a todas y cada una de las fuentes de datos

### Modelo canónico

La llave temporal principal fue fecha\_orden\_mes, derivada de año y mes.

$$fecha\_orden\_mes = anio * 12 + mes$$

Esta llave permitió ordenar los eventos de consulta, toma de muestra, defunción y pruebas reactivas dentro de un mismo eje temporal. El indicador de VIH/SIDA se definió mediante códigos CIE-10 B20 a B24 en las fuentes que contienen diagnóstico o causa de defunción. En HGM se aplicó sobre CODIGO; en Defunciones sobre CAUSA\_DEF.

$$vih\_flag = 1 \text{ si el código CIE inicia con B20, B21, B22, B23 o B24}$$

En VIH RED, el indicador principal fue clínico y se centró en CD4. Se creó el indicador de detección tardía cuando el valor de CD4 fue menor o igual a 200.

$$deteccion\_tardia = 1 \text{ si } CD4\_A \leq 200$$

### Métricas canónicas por fuente

Cada fuente aportara una dimensión distinta del fenómeno: atención clínica, laboratorio, mortalidad y pruebas reactivas.

| Métrica                   | Fuente | Agregación                               | Nivel de comparación     |
|---------------------------|--------|------------------------------------------|--------------------------|
| total_consultas           | HGM    | COUNT(*)                                 | Mes                      |
| consultas_vih             | HGM    | Conteo de registros con vih_flag = 1     | Mes, sexo, grupo de edad |
| consultas_primera_vez     | HGM    | Conteo de consultas con tipo primera vez | Mes, sexo, grupo de edad |
| consultas_vih_primera_vez | HGM    | Conteo de consultas VIH de primera vez   | Mes                      |

|                              |             |                                             |                          |
|------------------------------|-------------|---------------------------------------------|--------------------------|
| muestras_vih                 | VIH RED     | COUNT(*)                                    | Mes, sexo, grupo de edad |
| cd4_promedio                 | VIH RED     | Promedio de CD4_A                           | Mes, sexo, grupo de edad |
| casos_cd4_bajo               | VIH RED     | Conteo con vih_tardio_flag = 1              | Mes, sexo, grupo de edad |
| pct_cd4_bajo                 | VIH RED     | Proporción de casos con CD4 bajo            | Mes, sexo, grupo de edad |
| defunciones_totales          | Defunciones | COUNT(*)                                    | Mes, sexo, grupo de edad |
| defunciones_vih              | Defunciones | Conteo con vih_flag = 1                     | Mes, sexo, grupo de edad |
| pruebas_reactivas            | CEC         | Valor anual integrado al calendario mensual | Mes por réplica anual    |
| porcentaje_pruebas_reactivas | CEC         | Porcentaje anual de pruebas reactivas       | Mes por réplica anual    |

Tabla 4 - Métricas canónicas por fuente

## Heterogeneidad

### Heterogeneidad sintáctica

- Las fechas aparecen con nombres distintos según la fuente: FECHA en HGM, FECHA\_TOMA en VIH RED y FECHA\_OCURREN en Defunciones.
- Aunque las tres fechas se usan para construir una serie mensual, no se cargan directamente con el mismo nombre ni con el mismo tratamiento. Por eso se normalizan y se derivan los campos FECHA\_ANIO\_MES y FECHA\_ORDEN\_MES.
- HGM y Defunciones se descargan como archivos separados por año, mientras que VIH RED se trabaja desde un archivo completo. Por eso HGM y Defunciones requieren combinación previa.
- Los encabezados y textos tienen diferencias de mayúsculas, acentos, espacios y signos. Esto afecta variables como diagnóstico, especialidad, sexo y entidad.

### Heterogeneidad estructural

- HGM contiene registros de consultas otorgadas. Sus campos principales son fecha, tipo de consulta, procedencia, sexo, edad, especialidad, código CIE y descripción diagnóstica.
- VIH RED contiene registros de muestras y variables clínicas. Sus campos principales son fecha de toma, sexo, género, edad, municipio, seguridad social, carga viral y CD4.
- Defunciones contiene eventos de muerte. Sus campos principales son fecha de ocurrencia, fecha de nacimiento, causa de defunción, sexo, edad recalculada, entidad y municipio de ocurrencia.
- CEC no tiene registros individuales. Funciona como fuente auxiliar agregada anual con indicadores de pruebas reactivas.
- Por esta diferencia estructural, no se construye una tabla única de personas. La integración se hace por vistas SQL y métricas agregadas.

## Heterogeneidad de representación

- Ciudad de México se representa como texto en HGM y VIH RED, mientras que en Defunciones se identifica mediante código de entidad. Para Defunciones se usa ENT\_OCURRE = 9.
- El sexo se representa como texto en HGM, como combinación de sexo/género en VIH RED y como código en Defunciones. Se homologa a una codificación común para las vistas.
- La edad aparece como dato directo en HGM y VIH RED. En Defunciones se recalcula a partir de FECHA\_NACIM y FECHA\_OCURRE.
- Los grupos de edad se derivan a partir de la edad ya estandarizada, para permitir cruces por grupo\_edad.
- CEC sólo tiene información anual, por lo que se integra por año y se replica en el calendario mensual.

## Heterogeneidad semántica

- La fecha no significa lo mismo en todas las fuentes. En HGM representa una consulta; en VIH RED representa toma de muestra; en Defunciones representa ocurrencia de muerte.
- El indicador VIH tampoco tiene el mismo sentido. En HGM, vih\_flag identifica consultas con diagnóstico CIE-10 B20-B24. En Defunciones, vih\_flag identifica muertes con causa B20-B24.
- En VIH RED no se usa vih\_flag de la misma forma, porque la base ya corresponde a muestras relacionadas con VIH. En esa fuente se usa VIH\_TARDIO\_FLAG para identificar detección tardía a partir de CD4 menor o igual a 200.
- CD4 no equivale a consulta ni a defunción. Se usa como indicador clínico de severidad o posible detección tardía.
- CEC no representa pacientes ni consultas. Se usa como referencia auxiliar de pruebas reactivas para contextualizar cambios en consultas, laboratorio y defunciones.
- Por estas diferencias, la comparación se hace por indicadores agregados mensuales, no por unión directa de registros individuales.

## Schema matching

| Atributo canónico | HGM             | VIH RED         | Defunciones            | CEC                | Notas                                 |
|-------------------|-----------------|-----------------|------------------------|--------------------|---------------------------------------|
| Fecha base        | FECHA           | FECHA_TOMA      | FECHA_OCURRE           | año                | CEC no tiene fecha mensual individual |
| Año               | Derivado        | Derivado        | ANIO_OCURRE o derivado | año                | En vistas se usa calendario mensual   |
| Mes               | Derivado        | Derivado        | MES_OCURRE o derivado  | No aplica          | CEC se replica por año                |
| Llave mensual     | FECHA_ORDEN_MES | FECHA_ORDEN_MES | FECHA_ORDEN_MES        | año vía calendario | Llave principal de federación         |


|                         |                         |                 |                  |                   |                                    |
|-------------------------|-------------------------|-----------------|------------------|-------------------|------------------------------------|
| Sexo                    | SEXO                    | SEXO            | SEXO             | No aplica         | Requiere homologación              |
| Género                  | No aplica               | GENERO          | No aplica        | No aplica         | Sólo aplica a VIH RED              |
| Edad                    | EDAD                    | EDAD            | EDAD recalculada | No aplica         | En defunciones se deriva de fechas |
| Grupo de edad           | Derivado                | Derivado        | Derivado         | No aplica         | Se usa para vistas agregadas       |
| Indicador VIH           | VIH_FLAG                | No aplica       | VIH_FLAG         | No aplica         | B20-B24                            |
| CD4                     | No aplica               | CD4_A           | No aplica        | No aplica         | Sólo VIH RED                       |
| Detección tardía        | No aplica               | VIH_TARDIO_FLAG | No aplica        | No aplica         | CD4 <= 200                         |
| Código CIE              | CODIGO                  | No aplica       | CAUSA_DEF        | No aplica         | Diagnóstico o causa                |
| Descripción diagnóstica | DESCRIPCION_DIAGNOSTICO | No aplica       | No aplica        | No aplica         | Base textual para FAISS            |
| Pruebas reactivas       | No aplica               | No aplica       | No aplica        | pruebas_reactivas | Fuente auxiliar anual              |

## Schema mapping

| Regla                 | Fuente      | Entrada                   | Salida canónica | Detalle                                                                  |
|-----------------------|-------------|---------------------------|-----------------|--------------------------------------------------------------------------|
| Derivar llave mensual | HGM         | FECHA_ANIO_MES            | FECHA_ORDEN_MES | Convertir año-mes a orden temporal con $\text{anio} * 12 + \text{mes}$ . |
| Derivar llave mensual | VIH RED     | FECHA_ANIO_MES            | FECHA_ORDEN_MES | Misma regla mensual.                                                     |
| Derivar llave mensual | Defunciones | FECHA_ANIO_MES            | FECHA_ORDEN_MES | Misma regla mensual.                                                     |
| Estandarizar sexo     | HGM         | SEXO                      | sexo            | Masculino/Femenino y variantes se homologan a codificación común.        |
| Separar sexo/género   | VIH RED     | sexo original             | sexo, genero    | Se separa el valor combinado para conservar variables comparables.       |
| Estandarizar sexo     | Defunciones | SEXO                      | sexo            | Códigos válidos se homologan a la misma codificación usada en vistas.    |
| Calcular edad         | Defunciones | FECHA_NACIM, FECHA_OCURRE | edad_anios      | Diferencia de años entre nacimiento y ocurrencia.                        |
| Agrupar edad          | Todas       | edad_anios                | grupo_edad      | Asignación a grupos analíticos.                                          |
| Detectar VIH/SIDA     | HGM         | CODIGO                    | vih_flag        | 1 si inicia con B20-B24.                                                 |

|                   |             |             |                            |                                    |
|-------------------|-------------|-------------|----------------------------|------------------------------------|
| Detectar VIH/SIDA | Defunciones | CAUSA_DEF   | vih_flag                   | 1 si inicia con B20-B24.           |
| Detectar CD4 bajo | VIH RED     | CD4_A       | vih_tardio_flag            | 1 si CD4 <= 200.                   |
| Integrar CEC      | CEC         | anio        | indicador mensual auxiliar | Unión anual al calendario mensual. |
| Filtrar CDMX      | HGM         | PROCEDENCIA | cdmx_flag                  | Conservar Ciudad de México.        |
| Filtrar CDMX      | VIH RED     | estado      | cdmx_flag                  | Conservar Ciudad de México.        |
| Filtrar CDMX      | Defunciones | ENT_OCURRE  | cdmx_flag                  | Conservar ocurrencia en CDMX.      |


## 6. Diagrama que presente las relaciones entre las diferentes fuentes de datos



## 7. Procedimiento realizado para la integración de cada fuente de datos

La integración se realizó por etapas. Primero se conservaron los datos crudos. Después se generaron archivos combinados y filtrados a Ciudad de México. Luego se aplicó perfilado inicial, limpieza, deduplicación, postperfilado y transformación. Finalmente, los archivos transformados se cargaron a PostgreSQL para crear vistas federadas.





Flujo por fuente

| Fuente      | Archivo de entrada                                                  | Filtro CDMX                    | Archivo filtrado                           | Archivo limpio                                    | Sin duplicados                                                   | Transformado                                                                  | Tabla SQL             |
|-------------|---------------------------------------------------------------------|--------------------------------|--------------------------------------------|---------------------------------------------------|------------------------------------------------------------------|-------------------------------------------------------------------------------|-----------------------|
| HGM         | CONSULTAS_OTORGADAS_2019.csv a CONSULTAS_OTORGADAS_2023.csv         | PROCEDENCIA = Ciudad de México | consultas_HGM_cdmx_2019_2023.csv           | consultas_HGM_cdmx_2019_2023_limpio.csv           | consultas_HGM_cdmx_2019_2023_limpio_sin_duplicados.csv           | consultas_HGM_cdmx_2019_2023_limpio_sin_duplicados_transformado.csv           | consultas_hgm         |
| VIH RED     | vih_red_completa.csv                                                | estado = Ciudad de México      | vih_red_completa_cdmx_2019_2023.csv        | vih_red_completa_cdmx_2019_2023_limpio.csv        | vih_red_completa_cdmx_2019_2023_limpio_sin_duplicados.csv        | vih_red_completa_cdmx_2019_2023_limpio_sin_duplicados_transformado.csv        | vih_red               |
| Defunciones | defunciones_registradas_2019.csv a defunciones_registradas_2023.csv | ENTOCURR = 9                   | defunciones_registradas_cdmx_2019_2023.csv | defunciones_registradas_cdmx_2019_2023_limpio.csv | defunciones_registradas_cdmx_2019_2023_limpio_sin_duplicados.csv | defunciones_registradas_cdmx_2019_2023_limpio_sin_duplicados_transformado.csv | defunciones           |
| CEC         | Tabla auxiliar anual                                                | No aplica                      | No aplica                                  | No aplica                                         | No aplica                                                        | No aplica                                                                     | pruebas_reactivas_cec |

Tabla 5 - Resumen de flujo por fuente

Tablas base PostgreSQL

| Tabla | Fuente | Función en la integración |
|-------|--------|---------------------------|
|-------|--------|---------------------------|

|                       |             |                                                                            |
|-----------------------|-------------|----------------------------------------------------------------------------|
| consultas_hgm         | HGM         | Contiene consultas, diagnósticos, sexo, edad, código CIE y marca VIH/SIDA. |
| vih_red               | VIH RED     | Contiene muestras, CD4, carga viral, sexo, edad y detección tardía.        |
| defunciones           | Defunciones | Contiene eventos de muerte, causa CIE, sexo, edad y marca VIH/SIDA.        |
| pruebas_reactivas_cec | CEC         | Contiene indicadores anuales auxiliares de pruebas reactivas.              |

Tabla 6 - Tablas en PostgreSQL

## Vistas SQL utilizadas

- **`vw\_calendario\_mensual`**: se genera a partir del calendario mensual y usa `fecha\_orden\_mes` como llave. Define el eje mensual del periodo 2019-2023.
- **`vw\_pruebas\_reactivas\_mensual`**: integra la fuente auxiliar CEC con el calendario mensual mediante `anio` y `fecha\_orden\_mes`. Replica el indicador anual de pruebas reactivas al calendario mensual.
- **`vw\_consultas\_hgm\_mensual`**: se construye desde HGM y usa `fecha\_orden\_mes`. Resume consultas totales y consultas asociadas a VIH por mes.
- **`vw\_vih\_red\_mensual`**: se construye desde VIH RED y usa `fecha\_orden\_mes`. Resume muestras, CD4 y detección tardía por mes.
- **`vw\_defunciones\_mensual`**: se construye desde Defunciones y usa `fecha\_orden\_mes`. Resume defunciones totales y defunciones asociadas a VIH por mes.
- **`vw\_hgm\_vector\_cie\_mensual`**: se construye desde HGM y usa `fecha\_orden\_mes` y `codigo`. Prepara diagnósticos y códigos CIE para el componente vectorial FAISS.
- **`vw\_metricas\_mensuales\_integradas`**: integra HGM, VIH RED, Defunciones y CEC mediante `fecha\_orden\_mes`. Concentra indicadores generales por mes.
- **`vw\_metricas\_mensuales\_integradas\_sexo`**: integra HGM, VIH RED y Defunciones mediante `fecha\_orden\_mes` y `sexo`. Permite comparar indicadores por sexo.
- **`vw\_metricas\_mensuales\_integradas\_grupo\_edad`**: integra HGM, VIH RED y Defunciones mediante `fecha\_orden\_mes` y `grupo\_edad`. Permite comparar indicadores por grupo de edad.

## Resumen de datos cargados en POSTGRESLQ

| Tabla o vista                               | Registros |
|---------------------------------------------|-----------|
| consultas_hgm                               | 945,424   |
| vih_red                                     | 9,019     |
| defunciones                                 | 490,161   |
| pruebas_reactivas_cec                       | 5         |
| vw_calendario_mensual                       | 60        |
| vw_metricas_mensuales_integradas            | 60        |
| vw_metricas_mensuales_integradas_sexo       | 120       |
| vw_metricas_mensuales_integradas_grupo_edad | 420       |
| vw_hgm_vector_cie_mensual                   | 110,066   |

Tabla 7 - Datos cargados a PostgreSQL

## 8. Procedimiento realizado para el perfilado de datos

El preperfilado se aplicó después de fusionar y filtrar las fuentes a Ciudad de México. Su objetivo fue revisar la estructura inicial de cada base antes de modificarla: volumen de registros, columnas disponibles, valores nulos, cardinalidad, rangos numéricos, fechas, sexo, edad, códigos CIE y variables clínicas. Esta etapa sirvió para definir reglas de limpieza diferenciadas por fuente, ya que HGM, VIH RED y Defunciones no tenían la misma estructura ni la misma semántica.

El perfilado se realiza por fuente. HGM representa consultas otorgadas; VIH RED aporta muestras clínicas; Defunciones contiene defunciones.

### 8.1 Archivos perfilados y alcance inicial

| Archivo perfilado                          | Filas   | Columnas | Periodo detectado                         | Problemas relevantes                                                             | iniciales |
|--------------------------------------------|---------|----------|-------------------------------------------|----------------------------------------------------------------------------------|-----------|
| consultas_HGM_cdmx_2019_2023.csv           | 956,663 | 9        | 2020-01-01 a 2023-12-31                   | 1 edad negativa; 4 variantes de sexo; texto diagnóstico no normalizado.          |           |
| vih_red_completa_cdmx_2019_2023.csv        | 9,221   | 15       | 2019-07-17 a 2023-12-14                   | Nulos en colonia, municipio, seguridad social, CV y edad; sexo/género combinado. |           |
| defunciones_registradas_cdmx_2019_2023.csv | 498,110 | 63       | 1985-04-10 a 2023-12-31 antes de limpieza | Fechas anteriores a 2019; año 9999; mes 99; sexo 9; edad codificada.             |           |

Tabla 8 - Archivos perfilados

HGM tenía estructura compacta y sin nulos en columnas principales, pero necesitaba normalizar sexo, edad y texto diagnóstico. VIH RED tenía menor volumen, pero problemas de completitud en variables territoriales y clínicas. Defunciones fue la fuente con mayor complejidad estructural: muchas columnas, fechas fuera del rango y edad original codificada de forma no directa.

### 8.2 Preperfilado de HGM

La base de consultas HGM quedó filtrada a Ciudad de México con 956,663 registros y 9 columnas. El preperfilado no detectó nulos en las columnas principales, pero sí mostró una edad mínima de -5, lo que indicó la necesidad de eliminar un registro inválido. También se detectaron cuatro variantes en sexo: FEMENINO, MASCULINO, FEMENINO 1 y MASCULINO 1. Esto justificó una regla de homologación antes de integrar la fuente con las demás bases.

| Columna                 | Compleitud | Nulos | Cardinalidad |
|-------------------------|------------|-------|--------------|
| FECHA                   | 100.00%    | 0     | 1,455        |
| TIPO_CONSULTA           | 100.00%    | 0     | 2            |
| PROCEDENCIA             | 100.00%    | 0     | 1            |
| SEXO                    | 100.00%    | 0     | 4            |
| EDAD                    | 100.00%    | 0     | 114          |
| ESPECIALIDAD            | 100.00%    | 0     | 196          |
| CODIGO                  | 100.00%    | 0     | 7,507        |
| DESCRIPCION_DIAGNOSTICO | 100.00%    | 0     | 7,522        |

Tabla 9 - Resumen consultas HGM




Gráfico 1 - Histograma sexo en HGM antes de limpieza




Gráfico 2 - Histograma de edad en HGM antes de limpieza

### 8.3 Preperfilado de VIH RED / CONAHCYT

VIH RED tuvo 9,221 registros y 15 columnas después del filtrado territorial. A diferencia de HGM, esta fuente concentró problemas de completitud. La columna colonia estaba vacía en todos los registros, municipio tenía 978 nulos, seguridad social 413, CV 23 y edad 11. También se detectó que sexo y género venían combinados en una misma columna, con valores como Hombre cis, Mujer cis, Mujer trans y Hombre trans.

| Columna          | Completitud | Nulos | Cardinalidad |
|------------------|-------------|-------|--------------|
| id_muestra       | 100.00%     | 0     | 9,221        |
| fecha_toma       | 100.00%     | 0     | 915          |
| sexo             | 100.00%     | 0     | 4            |
| edad             | 99.88%      | 11    | 62           |
| edad_rango       | 99.88%      | 11    | 6            |
| estado           | 100.00%     | 0     | 1            |
| municipio        | 89.39%      | 978   | 16           |
| seguridad_social | 95.52%      | 413   | 5            |
| cv               | 99.75%      | 23    | 503          |
| cd4_a            | 100.00%     | 0     | 808          |

Gráfico 3 - Resumen preperfilado VIH RED CONAHCYT




Gráfico 4 - Histograma de sexo para VIH




Gráfico 5 - Histograma de edad en VIH antes de limpieza




Gráfico 6 - Histograma de CD4 en VIH antes de limpieza

## 8.4 Preperfilado de Defunciones

Defunciones fue la fuente con más problemas de preperfilado. Aunque el archivo ya estaba filtrado a Ciudad de México, el rango de fechas detectado incluía registros anteriores a 2019. También se identificaron valores inválidos o no útiles para el análisis mensual, como ANIO\_OCURREN=9999, MES\_OCURREN=99 y SEXO=9. La edad original no podía usarse directamente como años, ya que aparecía codificada con valores como 4055 o 4069. Por eso se recalculó a partir de fecha de nacimiento y fecha de ocurrencia.

| Columna       | Complejidad | Nulos | Cardinalidad |
|---------------|-------------|-------|--------------|
| FECHA_OCURREN | 99.99%      | 38    | 2,113        |
| FECHA_NACIM   | 98.53%      | 7,301 | 36,247       |
| CAUSA_DEF     | 100.00%     | 0     | 3,124        |
| SEXO          | 100.00%     | 0     | 3            |
| EDAD          | 100.00%     | 0     | 183          |
| ANIO_OCURREN  | 100.00%     | 0     | 19           |
| MES_OCURREN   | 100.00%     | 0     | 13           |
| ENT_OCURREN   | 100.00%     | 0     | 1            |
| MUN_OCURREN   | 100.00%     | 0     | 17           |

Tabla 10 - Resumen de preperfilado de Defunciones

El objetivo de limpieza en Defunciones es entonces llevar a la fuente al periodo 2019-2023, eliminar fechas no analizables, recalcular edad y reducir columnas que no aportaban a la integración.

## 9. Procedimiento realizado para la limpieza, deduplicación, postperfilado y transformación

Después del preperfilado se aplicó un proceso en cuatro subetapas: limpieza y estandarización, deduplicación, postperfilado, y transformación y reducción. Cada etapa generó archivos intermedios.

### 9.1 Limpieza y estandarización

La limpieza se aplicó por fuente por que cada base presentaba problemas distintos. En HGM se eliminó un registro con edad negativa, se estandarizó sexo, se limpió texto diagnóstico y se creó la marca de VIH/SIDA por CIE. En VIH RED se separó sexo/género, se imputaron valores faltantes y se creó la marca de detección tardía por CD4. En Defunciones se eliminaron registros fuera del periodo de análisis, se recalculó edad y se redujo el conjunto de columnas a las necesarias para integración.

| Fuente      | Entrada                                    | Salida                                            | Ref. iniciales | Reg. finales | Col. iniciales | Col. finales |
|-------------|--------------------------------------------|---------------------------------------------------|----------------|--------------|----------------|--------------|
| HGM         | consultas_HGM_cdmx_2019_2023.csv           | consultas_HGM_cdmx_2019_2023_limpio.csv           | 956,663        | 956,662      | 9              | 12           |
| VIH RED     | vih_red_completa_cdmx_2019_2023.csv        | vih_red_completa_cdmx_2019_2023_limpio.csv        | 9,221          | 9,221        | 15             | 13           |
| Defunciones | defunciones_registradas_cdmx_2019_2023.csv | defunciones_registradas_cdmx_2019_2023_limpio.csv | 498,110        | 490,336      | 63             | 20           |

Tabla 11 - Resumen de cambios

## Estrategias de limpieza implementadas

- 1) **Filtrado territorial a Ciudad de México.** Se conservó sólo el alcance territorial definido para el proyecto. En HGM se filtró por PROCEDENCIA, en VIH RED por estado y en Defunciones por ENT\_OCURRE = 9.
  - **Resultado:** HGM quedó con 956,663 registros; VIH RED con 9,221 registros; Defunciones con 498,110 registros después del filtrado CDMX.
- 2) **Normalización de fechas.** Se convirtieron fechas a un formato uniforme para poder derivar año, mes y FECHA\_ANIO\_MES. Esto permitió preparar las fuentes para integración mensual.
  - **Resultado:** se creó FECHA\_ANIO\_MES en HGM, VIH RED y Defunciones. En Defunciones se eliminaron 637 registros con fecha anterior a 2019.
- 3) **Corrección y homologación de sexo.** Se estandarizaron los valores de sexo para que pudieran compararse entre fuentes. HGM tenía variantes como FEMENINO 1 y MASCULINO 1; VIH RED mezclaba sexo y género; Defunciones usaba codificación numérica.
  - **Resultado:** HGM redujo sexo de 4 variantes a 2 categorías; VIH RED generó variables separadas de SEXO y GENERO; Defunciones conservó codificación comparable para integración.
- 4) **Separación de sexo y género en VIH RED.** La columna original combinaba valores como Hombre cis, Mujer cis, Mujer trans y Hombre trans. Se separó la información para conservar sexo comparable y género como variable propia.
  - **Resultado:** se procesaron 9,221 registros y se generaron las variables SEXO y GENERO.
- 5) **Tratamiento de edad inválida o no usable.** En HGM se detectó una edad negativa. En Defunciones la edad original estaba codificada y no era directamente interpretable como años, por lo que se recalculó con FECHA\_NACIM y FECHA\_OCURRE.
  - **Resultado:** HGM eliminó 1 registro y pasó de 956,663 a 956,662 registros; Defunciones recalculó edad para 490,336 registros y eliminó 7,137 registros donde no fue posible calcularla.
- 6) **Creación de grupos de edad.** Se derivó EDAD\_RANGO para comparar fuentes por grupos etarios y no sólo por edad individual.
  - **Resultado:** HGM, VIH RED y Defunciones quedaron con variable de grupo de edad para integración posterior por grupo\_edad.
- 7) **Detección de VIH/SIDA con CIE-10 B20-B24.** Se creó VIH\_FLAG en HGM y Defunciones usando códigos CIE que inician con B20, B21, B22, B23 o B24.
  - **Resultado:** HGM y Defunciones quedaron con un indicador binario comparable para consultas y defunciones asociadas a VIH/SIDA.

- 8) **Creación de indicador de detección tardía por CD4.** En VIH RED se creó VIH\_TARDIO\_FLAG a partir de CD4\_A. La regla usada fue marcar como 1 los registros con CD4 menor o igual a 200.
  - **Resultado:** los 9,221 registros de VIH RED quedaron con indicador clínico de detección tardía.
- 9) **Imputación de valores faltantes en VIH RED.** Se imputaron valores faltantes en variables necesarias para mantener registros dentro del análisis. Edad se imputó con 32; municipio y seguridad social con SIN\_DATO; CV con 4.6514.
  - **Resultado:** se imputaron 11 edades, 978 municipios, 413 valores de seguridad social y 23 valores de CV.
- 10) **Eliminación de columnas sin utilidad analítica o con nulos excesivos.** Se retiraron columnas que no aportaban al modelo canónico o que no podían usarse con calidad suficiente. En VIH RED se eliminaron COLONIA, CP, RESISTENCIA, CLUSTER\_ID y GRADO. En Defunciones se redujo el conjunto de 63 a 20 columnas.
  - **Resultado:** VIH RED pasó de 15 a 13 columnas; Defunciones pasó de 63 a 20 columnas después de limpieza.
- 11) **Normalización de texto diagnóstico.** Se limpiaron descripciones diagnósticas para reducir diferencias por acentos, signos, espacios y variantes textuales.
  - **Resultado:** en HGM se corrigieron 339,349 descripciones diagnósticas.
- 12) **Creación de identificadores técnicos.** Se agregaron identificadores internos para poder rastrear registros durante limpieza y deduplicación.
  - **Resultado:** HGM incorporó ID\_REGISTRO; Defunciones incorporó ID\_REGISTRO\_DEF; VIH RED conservó ID\_MUESTRA.
- 13) **Reducción de registros fuera de rango en Defunciones.** Se eliminaron registros con problemas de fecha y edad no calculable para restringir la base al periodo y estructura definidos.
  - **Resultado:** Defunciones pasó de 498,110 a 490,336 registros en limpieza; se eliminaron 7,774 registros en total.

## 9.2 Deduplicación

La deduplicación se aplicó sobre los archivos limpios. El proceso usó blocking para reducir comparaciones y después evaluó similitud entre registros dentro de cada bloque. La regla de conservación fue uniforme: en cada componente conectado se conservó el registro con identificador mínimo y se eliminaron los registros redundantes. Esto genera un registro sobreviviente operativo, no un golden record enriquecido con fusión atributo por atributo.



|                    |                                                |                                            |     |
|--------------------|------------------------------------------------|--------------------------------------------|-----|
| <b>HGM</b>         | FECHA_ANIO_MES, SEXO, EDAD_RANGO, ESPECIALIDAD | TIPO_CONSULTA, SEXO, EDAD, CODIGO, FECHA   | 5   |
| <b>VIH RED</b>     | FECHA_ANIO_MES, EDAD_RANGO, MUNICIPIO          | SEXO, GENERO, EDAD, CD4_A, FECHA_TOMA      | 4.5 |
| <b>Defunciones</b> | FECHA_ANIO_MES, EDAD, MUN_OCURRE               | CAUSA_DEF, SEXO, FECHA_OCURRE, FECHA_NACIM | 4   |

Tabla 12 - Estrategia deduplicación

| Fuente             | Registros antes | Pares candidatos | Pares coincidentes | % pares coincidentes | Registros eliminables | Registros únicos finales |
|--------------------|-----------------|------------------|--------------------|----------------------|-----------------------|--------------------------|
| <b>HGM</b>         | 956,662         | 20,610,628       | 12,806             | 0.0621%              | 11,238                | 945,424                  |
| <b>VIH RED</b>     | 9,221           | 34,937           | 221                | 0.6326%              | 202                   | 9,019                    |
| <b>Defunciones</b> | 490,336         | 3,778,960        | 147                | 0.0039%              | 146                   | 490,190                  |

Tabla 13 - Resultados deduplicación




Gráfico 7 - Registros eliminados por deduplicación por fuente.

HGM concentró el mayor número de registros eliminables porque también fue la fuente con mayor volumen de consultas. En VIH RED y Defunciones la deduplicación eliminó menos registros, pero ayudó a evitar doble conteo antes de la transformación y la carga relacional.

### 9.3 Postperfilado

El postperfilado revisó las versiones limpias y sin duplicados. Esta etapa permitió confirmar que las fuentes quedaron con nulos controlados en las columnas usadas para integración, variables derivadas disponibles y distribuciones más consistentes. También permitió comparar el estado inicial contra el estado posterior del proceso.

| Fuente     | Archivo postperfilado                                  | Filas   | Columnas | Nulos finales             | Cambios principales                    |
|------------|--------------------------------------------------------|---------|----------|---------------------------|----------------------------------------|
| <b>HGM</b> | consultas_HGM_cdmx_2019_2023_limpio_sin_duplicados.csv | 945,424 | 12       | 0 en columnas principales | Sexo reducido a 2 valores; edad mínima |

|                    |                                                                  |         |    |                           |                                                                                     |
|--------------------|------------------------------------------------------------------|---------|----|---------------------------|-------------------------------------------------------------------------------------|
|                    |                                                                  |         |    |                           | corregida a 0; diagnósticos normalizados.                                           |
| <b>VIH RED</b>     | vih_red_completa_cdmx_2019_2023_limpio_sin_duplicados.csv        | 9,019   | 13 | 0 en columnas principales | Sexo/género o separado; CD4 y CV completos; municipio y seguridad social imputados. |
| <b>Defunciones</b> | defunciones_registradas_cdmx_2019_2023_limpio_sin_duplicados.csv | 490,190 | 20 | 0 en columnas principales | Edad recalculada; fechas dentro del periodo; columnas reducidas.                    |

Tabla 14 - Postperfilado




Gráfico 8 - Histograma de sexo en Consultas en postperfilado




Gráfico 9 - Frecuencia de VIH FLAG en Consultas postperfilado




Gráfico 10 - Histograma edad Consultas postperfilado




Gráfico 11 - Histograma sexo Defunciones postperfilado




Gráfico 12 - Frecuencia VIH FLAG Defunciones postperfilado




Gráfico 13 - Histograma edad Defunciones postperfilado




Gráfico 14 - Histograma sexo VIH\_RED postperfilado




Gráfico 15 - Histograma VIH Tardío VIH\_RED postperfilado




Gráfico 16 - Histograma CD4 VIH\_RED postperfilado




Gráfico 17 - Histograma Carga Viral VIH\_RED postperfilado




Gráfico 18 - Histograma Edad VIH\_RED postperfilado

## 9.4 Transformación y reducción

La transformación preparó las fuentes para carga relacional e integración. En esta etapa se generó `FECHA\_ORDEN\_MES`, se codificaron variables categóricas, se escalaron variables numéricas y se eliminaron columnas redundantes.

| Fuente      | Registros entrada/salida | Columnas entrada/salida | Variables transformadas                         | Variables escaladas o codificadas                                                  | Pérdida de registros   |
|-------------|--------------------------|-------------------------|-------------------------------------------------|------------------------------------------------------------------------------------|------------------------|
| HGM         | 945,424 / 945,424        | 12 / 12                 | FECHA_ORDEN_MES, CODIGO_FREQ, ESPECIALIDAD_FREQ | EDAD escalada; SEXO codificado; CODIGO y ESPECIALIDAD conservados con frecuencia   | 0                      |
| VIH RED     | 9,019 / 9,019            | 13 / 11                 | FECHA_ORDEN_MES                                 | EDAD, CD4_A y CV escaladas; SEXO, GÉNERO, MUNICIPIO y SEGURIDAD_SOCIAL codificadas | 0                      |
| Defunciones | 490,190 / 490,161        | 20 / 17                 | FECHA_ORDEN_MES, CAUSA_DEF_FREQ                 | EDAD escalada; SEXO codificado; CAUSA_DEF conservada con frecuencia                | 29 por SEXO no binario |

| Fuente      | Columnas finales del CSV transformado                                                                                                                                                                       |
|-------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| HGM         | ID_REGISTRO, FECHA, FECHA_ORDEN_MES, TIPO_CONSULTA, SEXO, EDAD, ESPECIALIDAD, CODIGO, DESCRIPCION_DIAGNOSTICO, VIH_FLAG, CODIGO_FREQ, ESPECIALIDAD_FREQ                                                     |
| VIH RED     | ID_MUESTRA, FECHA_TOMA, FECHA_ORDEN_MES, SEXO, GÉNERO, EDAD, MUNICIPIO, SEGURIDAD_SOCIAL, CV, CD4_A, VIH_TARDIO_FLAG                                                                                        |
| Defunciones | ID_REGISTRO_DEF, FECHA_OCURRE, FECHA_ORDEN_MES, MES_OCURRE, CAUSA_DEF, SEXO, EDAD, ENT_RESID, FECHA_NACIM, ENT_REGIS, MUN_RESID, MUN_OCURRE, LUGAR_OCURRE, ASIST_MEDI, DERECHOHAB, VIH_FLAG, CAUSA_DEF_FREQ |




Gráfico 19 - Conservación de registros por etapa del proceso.




Gráfico 20 - Columnas por etapa y fuente.

La mayor reducción estructural ocurrió en Defunciones, que pasó de 63 columnas iniciales a 20 después de limpieza y 17 después de transformación. HGM aumentó de 9 a 12 columnas porque se añadieron identificadores y variables derivadas. VIH RED redujo columnas al eliminar atributos con baja utilidad para integración y conservar variables clínicas centrales.

## 9.5 Comparación del proceso

| Fuente      | Después filtrado CDMX | Después limpieza | Después deduplicación | Después transformación | Cambio principal                                                                                                 |
|-------------|-----------------------|------------------|-----------------------|------------------------|------------------------------------------------------------------------------------------------------------------|
| HGM         | 956,663               | 956,662          | 945,424               | 945,424                | Se eliminó edad inválida, se normalizó sexo y se redujeron duplicados.                                           |
| VIH RED     | 9,221                 | 9,221            | 9,019                 | 9,019                  | Se imputaron nulos, se separó sexo/género y se creó detección tardía por CD4.                                    |
| Defunciones | 498,110               | 490,336          | 490,190               | 490,161                | Se filtró periodo, se recalculó edad, se redujeron columnas y se excluyeron sexos no binarios en transformación. |

Tabla 15 - Comparación registros durante el proceso

| Fuente      | Columnas iniciales | Columnas después de limpieza | Columnas después de transformación |
|-------------|--------------------|------------------------------|------------------------------------|
| HGM         | 9                  | 12                           | 12                                 |
| VIH RED     | 15                 | 13                           | 11                                 |
| Defunciones | 63                 | 20                           | 17                                 |

Tabla 16 - Comparación columnas durante el proceso

El resultado final de la sección fue un conjunto de tres archivos limpios, tres archivos sin duplicados y tres archivos transformados. Estos últimos fueron la base para la carga a PostgreSQL y para la construcción de vistas mensuales, consultas SQL, grafo, corpus vectorial y respuestas con LLM local.

## 10. Procedimiento realizado para el análisis de los datos

El análisis se ejecutó sobre la base preparada, con tres capas de consulta: relacional, grafo y vectorial. La capa relacional concentró las vistas mensuales integradas; el grafo representó meses, periodos e indicadores; y el componente vectorial diagnósticos HGM por similitud textual. Sobre estas bases de datos se ejecutó el LLM local para recibir preguntas en lenguaje natural y generar respuestas estructuradas en JSON.

La ejecución final se organizó alrededor de 20 preguntas de negocio: 10 descriptivas y 10 predictivas.

| Componente        | Entrada o archivo usado                                             | Resultado dentro del análisis                                     |
|-------------------|---------------------------------------------------------------------|-------------------------------------------------------------------|
| SQL / PostgreSQL  | `vw_metricas_mensuales_integradas`, vistas por sexo y grupo de edad | Consultas agregadas por año, mes, periodo, sexo y grupo de edad.  |
| NetworkX          | `grafo_metricas_mensuales.json` y `grafo_metricas_mensuales.png`    | Representación de meses, periodos e indicadores agregados.        |
| FAISS / vectorial | `hgm_cie_mensual.faiss` y corpus HGM por CIE mensual                | Recuperación textual de diagnósticos HGM similares por CIE y mes. |
| LLM local         | `main.py`, `consultas_llm.py`, `respuestas_20_preguntas.json`       | Router de preguntas hacia SQL, grafo o búsqueda vectorial.        |

Tabla 17 - Componentes usados para el análisis de datos.

### Construcción del grafo con NetworkX

El grafo se construyó desde la vista `vw\_metricas\_mensuales\_integradas`. Cada mes del periodo 2019-2023 se transformó en un nodo, cada periodo de análisis en otro nodo, y cada indicador mensual en un nodo de indicador. Después se agregaron aristas para relacionar meses con su periodo, meses con indicadores y meses consecutivos.

| Elemento         | Descripción                                                                                           |
|------------------|-------------------------------------------------------------------------------------------------------|
| Script           | `code_python/crear_grafo_networkx.py`                                                                 |
| Fuente           | `vw_metricas_mensuales_integradas`                                                                    |
| Archivo generado | `grafo_metricas_mensuales.pkl`,<br>`grafo_metricas_mensuales.json`,<br>`grafo_metricas_mensuales.png` |
| Nodos            | 76: 60 meses, 3 periodos y 13 indicadores                                                             |
| Aristas          | 899: 60 pertenencias a periodo, 780 relaciones mes-indicador y 59 relaciones de mes siguiente         |
| Representa       | Meses, periodos e indicadores agregados                                                               |

Tabla 18 - Estructura técnica del grafo NetworkX.






Figura 7 - Grafo de periodos, meses e indicadores agregados.

## Construcción del componente vectorial con FAISS

El componente vectorial se construyó con diagnósticos HGM por similitud textual. La entrada fue la vista ``vw_hgm_vector_cie_mensual``, con registros agrupados por código CIE y mes. Para cada documento se combinó código, especialidad, descripción diagnóstica, total de registros y un indicador de mención de VIH en el texto. Después se aplicó TF-IDF, reducción SVD, normalización vectorial y carga en un índice FAISS de producto interno.

| Elemento                | Valor                                                                                      |
|-------------------------|--------------------------------------------------------------------------------------------|
| Script                  | <code>`code_python/crear_corpus_vectorial.py`</code>                                       |
| Vista de entrada        | <code>`vw_hgm_vector_cie_mensual`</code>                                                   |
| Corpus                  | <code>`hgm_corpus_cie_mensual.csv` y `hgm_corpus_cie_mensual.jsonl`</code>                 |
| Índice                  | <code>`hgm_cie_mensual.faiss`</code>                                                       |
| Vectorizador            | <code>`TfidfVectorizer(lowercase=True, strip_accents="unicode", ngram_range=(1,2))`</code> |
| Reducción               | <code>`TruncatedSVD(n_components=128)`</code>                                              |
| Documentos vectorizados | 110,066                                                                                    |
| Índice FAISS            | <code>`IndexFlatIP`</code> con vectores normalizados                                       |

Tabla 19 - Configuración del componente vectorial FAISS.

| Rank | Score  | Año-mes | CIE  | Diagnóstico recuperado              | Reg. |
|------|--------|---------|------|-------------------------------------|------|
| 1    | 0.9626 | 2023-09 | B210 | VIH resultante en sarcoma de Kaposi | 2    |
| 2    | 0.9626 | 2023-08 | B210 | VIH resultante en sarcoma de Kaposi | 2    |

|   |        |         |      |                                             |   |
|---|--------|---------|------|---------------------------------------------|---|
| 3 | 0.9572 | 2023-11 | B206 | VIH resultante en neumonía por Pneumocystis | 1 |
|---|--------|---------|------|---------------------------------------------|---|

Tabla 20 - Fragmento de recuperación vectorial con la consulta "VIH sida inmunodeficiencia".

## Correlación de indicadores

La correlación se calculó con Pearson sobre los 60 registros mensuales de la vista integrada. Se usaron pares válidos por columna.

| Par de indicadores                            | r       | Lectura técnica        |
|-----------------------------------------------|---------|------------------------|
| muestras_total vs casos_cd4_bajo              | 0.9491  | Positiva alta          |
| consultas_vih vs casos_cd4_bajo               | 0.6995  | Positiva moderada-alta |
| casos_cd4_bajo vs proporcion_cd4_bajo         | 0.6941  | Positiva moderada-alta |
| cd4_promedio vs proporcion_cd4_bajo           | -0.9692 | Negativa alta          |
| pruebas_reactivas vs pct_reactivas_consejeria | -0.8369 | Negativa alta          |

Tabla 21 - Correlaciones principales entre indicadores mensuales.

## Preguntas ejecutadas con el LLM

En esta parte se registran las preguntas enviadas al sistema. Para cada una se muestra la consulta generada, los datos devueltos por la ejecución y la respuesta verbal producida por el LLM:

**Pregunta 1. ¿Cómo cambiaron entre 2019 y 2023 las consultas relacionadas con VIH en Ciudad de México y cómo se compara esa tendencia con la de las defunciones por VIH/SIDA en el mismo periodo?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, SUM(consultas_vih) AS consultas_vih, SUM(defunciones_vih) AS defunciones_vih FROM vw_metricas_mensuales_integradas WHERE anio BETWEEN 2019 AND 2023 GROUP BY anio ORDER BY anio
```

- Datos proporcionados por la consulta: 5 filas. Columnas: anio, consultas\_vih, defunciones\_vih.

- Fragmento de salida:

```
2019 | consultas_vih=0 | defunciones_vih=526
2020 | consultas_vih=471 | defunciones_vih=549
2021 | consultas_vih=810 | defunciones_vih=440
2022 | consultas_vih=956 | defunciones_vih=478
2023 | consultas_vih=847 | defunciones_vih=464
```

Respuesta del LLM:

El resultado muestra una tendencia de consultas y defunciones por VIH en Ciudad de México entre 2019 y 2023. Las consultas aumentaron significativamente, pasando de 526 en 2019 a 956 en 2022, mientras que las defunciones disminuyeron, pasando de 549 en 2020 a 464 en 2023.

**Pregunta 2. ¿Cómo varió entre 2019 y 2023 la severidad clínica al diagnóstico, medida mediante CD4, y cómo se relaciona temporalmente con los cambios en consultas y defunciones?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, AVG(cd4_promedio) AS media_cd4, SUM(casos_cd4_bajo) AS
casos_bajo, SUM(defunciones_vih) AS defunciones_vih FROM
vw_metricas_mensuales_integradas WHERE anio BETWEEN 2019 AND 2023 GROUP BY
anio
```

- Datos proporcionados por la consulta: 5 filas. Columnas: anio, media\_cd4, casos\_bajo, defunciones\_vih.

- Fragmento de salida:

```
2019 | media_cd4=0.1905 | casos_bajo=183 | defunciones_vih=526
2020 | media_cd4=0.1419 | casos_bajo=803 | defunciones_vih=549
2021 | media_cd4=0.1285 | casos_bajo=1229 | defunciones_vih=440
2022 | media_cd4=0.1268 | casos_bajo=1196 | defunciones_vih=478
2023 | media_cd4=0.1356 | casos_bajo=921 | defunciones_vih=464
```

Respuesta del LLM:

El resultado muestra la variación en la severidad clínica al diagnóstico, medida mediante CD4, entre 2019 y 2023. La media de CD4 promedio disminuyó ligeramente (-12%) durante este período. Además, se observaron un aumento en los casos de CD4 bajo (23% más) y una disminución en las defunciones por VIH (-13%). Sin embargo, debido a la limitación de datos, no se puede interpretar con certeza la relación temporal entre estos cambios y otros factores.

**Pregunta 3. ¿Cómo cambió entre 2019 y 2023 el porcentaje anual de pruebas reactivas y cómo se comportaron, en ese mismo periodo, las consultas y las defunciones asociadas a VIH/SIDA?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, AVG(pct_reactivas_consejeria) AS
porcentaje_anual_pruebas_reactivas, SUM(consultas_vih) AS consultas_vih,
SUM(defunciones_vih) AS defunciones_vih FROM vw_metricas_mensuales_integradas
WHERE anio BETWEEN 2019 AND 2023 GROUP BY anio ORDER BY anio
```

- Datos proporcionados por la consulta: 5 filas. Columnas: anio, porcentaje\_anual\_pruebas\_reactivas, consultas\_vih, defunciones\_vih.

- Fragmento de salida:

```
2019 | porcentaje_anual_pruebas_reactivas=11.2 | consultas_vih=0 |
defunciones_vih=526
2020 | porcentaje_anual_pruebas_reactivas=14.3 | consultas_vih=471 |
defunciones_vih=549
2021 | porcentaje_anual_pruebas_reactivas=12.8 | consultas_vih=810 |
defunciones_vih=440
2022 | porcentaje_anual_pruebas_reactivas=10.7 | consultas_vih=956 |
defunciones_vih=478
2023 | porcentaje_anual_pruebas_reactivas=10.1 | consultas_vih=847 |
defunciones_vih=464
```

Respuesta del LLM:

El resultado muestra el porcentaje anual de pruebas reactivas, consultas y defunciones asociadas a VIH/SIDA entre 2019 y 2023. Los porcentajes anuales de pruebas reactivas disminuyen en promedio (11.2% en 2019, 10.1% en 2023), mientras que las consultas y defunciones aumentan en promedio (0 consultas en 2019, 847 en 2023). La vista previa muestra los datos detallados para cada año.

**Pregunta 4. ¿Qué diferencias se observan por sexo en consultas, CD4, defunciones y porcentaje de pruebas reactivas a lo largo del periodo 2019-2023?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT periodo, sexo_etiqueta, SUM(consultas_vih) AS consultas_vih,
SUM(defunciones_vih) AS defunciones_vih, AVG(cd4_promedio) AS cd4_promedio
FROM vw_metricas_mensuales_integradas_sexo WHERE anio BETWEEN 2019 AND 2023
GROUP BY periodo, sexo_etiqueta ORDER BY periodo
```

- Datos proporcionados por la consulta: 6 filas. Columnas: periodo, sexo\_etiqueta, consultas\_vih, defunciones\_vih, cd4\_promedio.

- Fragmento de salida:

```
PANDEMIA | FEMENINO_MUJER | consultas_vih=77 | defunciones_vih=107 |
cd4_promedio=0.1106
PANDEMIA | MASCULINO_HOMBRE | consultas_vih=502 | defunciones_vih=557 |
cd4_promedio=0.1292
POSTPANDEMIA | FEMENINO_MUJER | consultas_vih=376 | defunciones_vih=158 |
cd4_promedio=0.1216
POSTPANDEMIA | MASCULINO_HOMBRE | consultas_vih=1949 | defunciones_vih=1021 |
cd4_promedio=0.1311
PREPANDEMIA | FEMENINO_MUJER | consultas_vih=27 | defunciones_vih=74 |
```

```
cd4_promedio=0.1427
PREPANDEMIA | MASCULINO_HOMBRE | consultas_vih=153 | defunciones_vih=540 |
cd4_promedio=0.1933
```

Respuesta del LLM:

A lo largo del periodo 2019-2023, se observan diferencias significativas en consultas, CD4 y defunciones por sexo. Las mujeres presentan un aumento en las consultas y una disminución en las defunciones, mientras que los hombres tienen un aumento en las consultas y una disminución en el promedio de CD4. Sin embargo, es importante destacar que la muestra de datos es limitada a 6 filas y puede no reflejar tendencias más amplias.

**Pregunta 5. ¿Qué diferencias se observan por grupos de edad en consultas, severidad al diagnóstico y defunciones por VIH/SIDA durante el periodo de estudio?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT periodo, grupo_edad, SUM(consultas_vih) AS consultas_vih,
SUM(defunciones_vih) AS defunciones_vih, AVG(cd4_promedio) AS cd4_promedio,
SUM(casos_cd4_bajo) AS casos_cd4_bajo, AVG(proporcion_cd4_bajo) AS
proporcion_cd4_bajo_promedio FROM vw_metricas_mensuales_integradas_grupo_edad
GROUP BY periodo, grupo_edad, orden_grupo_edad ORDER BY periodo,
orden_grupo_edad
```

- Datos proporcionados por la consulta: 21 filas. Columnas: periodo, grupo\_edad, consultas\_vih, defunciones\_vih, cd4\_promedio, casos\_cd4\_bajo, proporcion\_cd4\_bajo\_promedio.

- Fragmento de salida:

```
PANDEMIA | 00_17 | consultas_vih=1 | defunciones_vih=4 | cd4_promedio=0.1348
| casos_cd4_bajo=1 | proporcion_cd4_bajo_promedio=0.25
PANDEMIA | 18_24 | consultas_vih=60 | defunciones_vih=24 |
cd4_promedio=0.1487 | casos_cd4_bajo=166 |
proporcion_cd4_bajo_promedio=0.3634
PANDEMIA | 25_34 | consultas_vih=158 | defunciones_vih=158 |
cd4_promedio=0.1334 | casos_cd4_bajo=608 |
proporcion_cd4_bajo_promedio=0.4901
PANDEMIA | 35_44 | consultas_vih=135 | defunciones_vih=159 |
cd4_promedio=0.1152 | casos_cd4_bajo=329 |
proporcion_cd4_bajo_promedio=0.5829
```

Respuesta del LLM:

Se observan diferencias significativas en consultas, defunciones por VIH/SIDA y CD4 promedio entre grupos de edad durante el periodo de estudio. Los adultos jóvenes (18-24 años) presentan altos niveles de consultas y defunciones, mientras que los adultos mayores (65+ años) tienen tasas más bajas de estas condiciones.

**Pregunta 6. ¿Cómo se comportaron antes, durante y después de la pandemia las consultas por VIH, los valores de CD4, las defunciones y el porcentaje de pruebas reactivas?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, mes, SUM(consultas_vih) AS consultas_vih, AVG(cd4_promedio) AS
cd4_promedio, SUM(defunciones_vih) AS defunciones_vih,
AVG(pct_reactivas_consejeria) AS pct_reactivas_consejeria FROM
vw_metricas_mensuales_integradas WHERE anio BETWEEN 2020 AND 2023 GROUP BY
anio, mes
```

- Datos proporcionados por la consulta: 48 filas. Columnas: anio, mes, consultas\_vih, cd4\_promedio, defunciones\_vih, pct\_reactivas\_consejeria.

- Fragmento de salida:

```
2020 | mes=1 | consultas_vih=88 | cd4_promedio=0.1999 | defunciones_vih=40 |
pct_reactivas_consejeria=14.3
2020 | mes=2 | consultas_vih=92 | cd4_promedio=0.1897 | defunciones_vih=48 |
pct_reactivas_consejeria=14.3
2020 | mes=3 | consultas_vih=52 | cd4_promedio=0.1711 | defunciones_vih=36 |
pct_reactivas_consejeria=14.3
2020 | mes=4 | consultas_vih=11 | cd4_promedio=NaN | defunciones_vih=48 |
pct_reactivas_consejeria=14.3
```

Respuesta del LLM:

El resultado muestra el comportamiento de las consultas por VIH, los valores de CD4, las defunciones y el porcentaje de pruebas reactivas antes, durante y después de la pandemia.

Se observa un aumento en las consultas por VIH en 2020, especialmente en los meses de enero a marzo. Los valores de CD4 son bajos en general, con una media anual de 0,14. El número de defunciones es significativo, especialmente en 2020.

En 2021, se observa un descenso en las consultas por VIH y un aumento en los valores de CD4. Sin embargo, el número de defunciones sigue siendo alto.

**Pregunta 7. ¿En qué periodos se observa una disminución simultánea o divergente entre consultas, porcentaje de pruebas reactivas y defunciones por VIH/SIDA?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT periodo, SUM(defunciones_vih) AS defunciones_vih,
AVG(pruebas_reactivas) AS pruebas_reactivas, SUM(consultas_vih) AS
consultas_vih FROM vw_metricas_mensuales_integradas GROUP BY periodo HAVING
```

$SUM(defunciones\_vih) * AVG(pruebas\_reactivas) < 0$  OR  
 $AVG(pruebas\_reactivas) * SUM(defunciones\_vih) > 0$

• Datos proporcionados por la consulta: 3 filas. Columnas: periodo, defunciones\_vih, pruebas\_reactivas, consultas\_vih.

• Fragmento de salida:

```
PANDEMIA | defunciones_vih=664 | pruebas_reactivas=4172.125 |
consultas_vih=579
POSTPANDEMIA | defunciones_vih=1179 | pruebas_reactivas=5008.6 |
consultas_vih=2325
PREPANDEMIA | defunciones_vih=614 | pruebas_reactivas=4290.5714 |
consultas_vih=180
```

Respuesta del LLM:

El resultado muestra 3 periodos: PANDEMIA, POSTPANDEMIA y PREPANDEMIA. En estos periodos se observa una disminución simultánea o divergente entre consultas, porcentaje de pruebas reactivas y defunciones por VIH/SIDA.

- PANDEMIA: Defunciones por VIH/SIDA (664) y consultas (579) disminuyen, mientras que el porcentaje de pruebas reactivas (4172) aumenta.
- POSTPANDEMIA: Defunciones por VIH/SIDA (1179) y consultas (2325) disminuyen, mientras que el porcentaje de pruebas reactivas (5008) aumenta.
- PREPANDEMIA: Defunciones por VIH/SIDA (614) y consultas (180) disminuyen, mientras que el porcentaje de pruebas reactivas (4290) aumenta.

**Pregunta 8. ¿Cómo cambió la proporción de consultas de primera vez frente a subsecuentes entre 2019 y 2023, y cómo se relaciona con la severidad clínica al diagnóstico y con la mortalidad?**

• Backend usado: SQL.

• Consulta generada:

```
SELECT anio, SUM(consultas_primera_vez) AS consultas_primera_vez,
SUM(consultas_subsecuente) AS consultas_subsecuente, AVG(cd4_promedio) AS
cd4_promedio, SUM(defunciones_vih) AS defunciones_vih FROM
vw_metricas_mensuales_integradas_sexo WHERE anio BETWEEN 2019 AND 2023 GROUP
BY anio
```

• Datos proporcionados por la consulta: 5 filas. Columnas: anio, consultas\_primera\_vez, consultas\_subsecuente, cd4\_promedio, defunciones\_vih.

• Fragmento de salida:

```
2019 | consultas_primera_vez=0 | consultas_subsecuente=0 |
cd4_promedio=0.1637 | defunciones_vih=526
```

```
2020 | consultas_primera_vez=65949 | consultas_subsecuente=79412 |
cd4_promedio=0.1284 | defunciones_vih=549
2021 | consultas_primera_vez=82540 | consultas_subsecuente=98056 |
cd4_promedio=0.1272 | defunciones_vih=440
2022 | consultas_primera_vez=131414 | consultas_subsecuente=160372 |
cd4_promedio=0.1224 | defunciones_vih=478
2023 | consultas_primera_vez=142738 | consultas_subsecuente=184943 |
cd4_promedio=0.1301 | defunciones_vih=464
```

#### Respuesta del LLM:

El resultado muestra el cambio en la proporción de consultas de primera vez frente a subsecuentes entre 2019 y 2023. Los años con mayor proporción de consultas de primera vez son 2020, 2021 y 2022, mientras que 2023 presenta una disminución en esta proporción.

La mortalidad (defunciones VIH) aumenta en los años posteriores a 2019, siendo el año con mayor cantidad de defunciones VIH 2020. La media del CD4 promedio también disminuye en los años posteriores a 2019, siendo el año con menor media 2022.

#### **Pregunta 9. ¿Qué patrón temporal muestran los casos con CD4 sugestivo de detección tardía y cómo coincide con los cambios en consultas y defunciones?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT fecha_orden_mes, anio, mes, cd4_promedio, total_consultas,
total_defunciones FROM vw_metricas_mensuales_integradas WHERE cd4_promedio <
350 AND anio BETWEEN 2019 AND 2023 GROUP BY fecha_orden_mes, anio, mes ORDER
BY fecha_orden_mes
```

- Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

#### Respuesta del LLM:

NO\_GENERADA. El campo `interpretacion` quedó como `null`.

#### **Pregunta 10. ¿Qué años del periodo 2019-2023 presentan la mayor discrepancia entre porcentaje de pruebas reactivas, demanda de atención y mortalidad por VIH/SIDA?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, (pruebas_reactivas * 100 / total_consultas) AS
porcentaje_pruebas_reactivas, (total_defunciones / total_consultas) AS
mortalidad_vih FROM vw_metricas_mensuales_integradas WHERE anio BETWEEN 2019
AND 2023 GROUP BY anio ORDER BY ABS((pruebas_reactivas * 100 /
total_consultas) - (total_defunciones / total_consultas)) DESC LIMIT 1
```



- Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

Respuesta del LLM:

NO\_GENERADA. El campo `interpretacion` quedó como `null`.

**Pregunta 11. ¿Qué combinación de cambios en consultas, valores de CD4 y porcentaje de pruebas reactivas permite anticipar periodos con mayor riesgo de incremento en defunciones por VIH/SIDA?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, mes, SUM(consultas_vih) AS consultas_vih, AVG(cd4_promedio) AS
cd4_promedio, MAX(pruebas_reactivas) AS pruebas_reactivas FROM
vw_metricas_mensuales_integradas WHERE pruebas_reactivas > 0 GROUP BY anio,
mes ORDER BY anio, mes
```

- Datos proporcionados por la consulta: 60 filas. Columnas: `anio`, `mes`, `consultas_vih`, `cd4_promedio`, `pruebas_reactivas`.

- Fragmento de salida:

```
2019 | mes=1 | consultas_vih=0 | cd4_promedio=NaN | pruebas_reactivas=4361
2019 | mes=2 | consultas_vih=0 | cd4_promedio=NaN | pruebas_reactivas=4361
2019 | mes=3 | consultas_vih=0 | cd4_promedio=NaN | pruebas_reactivas=4361
2020 | mes=1 | consultas_vih=88 | cd4_promedio=0.1999 |
pruebas_reactivas=3868
```

Respuesta del LLM:

El resultado muestra una tabla con datos de consultas, valores de CD4 y porcentaje de pruebas reactivas para cada mes de 2019 y 2020. Los meses con mayor riesgo de incremento en defunciones por VIH/SIDA son aquellos con altos niveles de consultas y bajos niveles de CD4.

Se observa un aumento significativo en las consultas durante los meses de enero y febrero de 2020, lo que se asocia con una mayor incidencia del virus. Sin embargo, el valor promedio de CD4 es relativamente bajo en estos meses, lo que sugiere una mayor vulnerabilidad a la enfermedad.

En contraste, los meses de marzo y abril de 2019 presentan un patrón similar, con altas consultas y bajos niveles de CD4. Sin embargo, el valor promedio de CD4 es ligeramente más alto en este período que en 2020.

**Pregunta 12. ¿La disminución en consultas y en porcentaje de pruebas reactivas permite predecir un aumento posterior en casos con CD4 bajo, consistente con detección tardía?**

• Backend usado: SQL.

• Consulta generada:

```
SELECT anio, mes, SUM(casos_cd4_bajo) AS casos_cd4_bajo,  
AVG(proporcion_cd4_bajo) AS proporcion_cd4_bajo FROM  
vw_metricas_mensuales_integradas WHERE pruebas_reactivas > 0 AND cd4_promedio  
< AVG(cd4_promedio) GROUP BY anio, mes ORDER BY anio, mes
```

• Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

Respuesta del LLM:

NO\_GENERADA. El campo interpretacion quedó como null.

**Pregunta 13. ¿Qué perfiles de sexo y edad presentan mayor probabilidad de concentrar diagnósticos con mayor severidad clínica en periodos de menor detección aparente?**

• Backend usado: SQL.

• Consulta generada:

```
SELECT sexo_etiqueta, edad_promedio_consultas, COUNT(*) AS  
diagnosticos_severidad_clinica FROM  
vw_metricas_mensuales_integradas_grupo_edad WHERE pruebas_reactivas < 1000  
GROUP BY sexo_etiqueta, edad_promedio_consultas ORDER BY  
diagnosticos_severidad_clinica DESC LIMIT 10
```

• Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

Respuesta del LLM:

NO\_GENERADA. El campo interpretacion quedó como null.

**Pregunta 14. ¿Qué variaciones en el porcentaje anual de pruebas reactivas permiten anticipar cambios posteriores en la demanda de atención clínica por VIH?**

• Backend usado: SQL.

• Consulta generada:

```
SELECT anio, AVG(pct_reactivas_consejeria) AS  
promedio_pct_reactivas_consejeria, AVG(pct_reactivas_otros_programas) AS  
promedio_pct_reactivas_otros_programas FROM vw_metricas_mensuales_integradas  
WHERE vih_flag = 1 GROUP BY anio ORDER BY anio
```

- Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

Respuesta del LLM:

NO\_GENERADA. El campo `interpretacion` quedó como `null`.

**Pregunta 15. ¿La combinación de menor actividad en consultas y mayor proporción de casos con CD4 bajo permite predecir periodos con mayor presión clínica futura?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, mes, SUM(consultas_vih) AS actividad_consultas,
AVG(proporcion_cd4_bajo) AS proporcion_cd4_bajo FROM
vw_metricas_mensuales_integradas_sexo GROUP BY anio, mes ORDER BY anio, mes
```

- Datos proporcionados por la consulta: 60 filas. Columnas: `anio`, `mes`, `actividad_consultas`, `proporcion_cd4_bajo`.

- Fragmento de salida:

```
2019 | mes=1 | actividad_consultas=0 | proporcion_cd4_bajo=NaN
2019 | mes=2 | actividad_consultas=0 | proporcion_cd4_bajo=NaN
2019 | mes=3 | actividad_consultas=0 | proporcion_cd4_bajo=NaN
2020 | mes=3 | actividad_consultas=52 | proporcion_cd4_bajo=0.535
```

Respuesta del LLM:

El resultado muestra una tabla con los periodos de 2019 y 2020, donde la actividad en consultas es menor y la proporción de casos con CD4 bajo es mayor. En particular, se observa que en el mes de marzo de 2020, la actividad en consultas es significativamente alta (52.0) mientras que la proporción de casos con CD4 bajo es moderadamente alta (0.535). Sin embargo, debido a la limitación de datos, no se puede determinar si esta combinación permite predecir periodos con mayor presión clínica futura.

**Pregunta 16. ¿Qué patrones temporales son más consistentes para anticipar si una caída en indicadores observados responde a reducción real del fenómeno o a subdetección?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT * FROM vw_metricas_mensuales_integradas WHERE anio = 2020 AND mes IN
(1, 2, 3) GROUP BY fecha_orden_mes HAVING COUNT(CASE WHEN cd4_promedio > 200
THEN 1 END) / SUM(cd4_promedio) > 0.5 OR COUNT(CASE WHEN pruebas_reactivas IS
NULL THEN 1 END) / SUM(pruebas_reactivas) > 0.7
```

- Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

Respuesta del LLM:

NO\_GENERADA. El campo `interpretacion` quedó como `null`.

**Pregunta 17. ¿Qué grupos de edad y sexo presentan mayor probabilidad de mostrar un patrón de detección tardía cuando disminuyen las consultas o cambia la proporción de pruebas reactivas?**

- Backend usado: SQL.
- Consulta generada:

```
SELECT grupo_edad, sexo_etiqueta, SUM(CASE WHEN edad_promedio_consultas > 45  
THEN 1 ELSE 0 END) AS deteccion_tardia FROM  
vw_metricas_mensuales_integradas_sexo GROUP BY grupo_edad, sexo_etiqueta  
ORDER BY deteccion_tardia DESC LIMIT 10
```

- Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

Respuesta del LLM:

NO\_GENERADA. El campo `interpretacion` quedó como `null`.

**Pregunta 18. ¿Los cambios observados en un año del porcentaje de pruebas reactivas permiten anticipar variaciones en las defunciones por VIH/SIDA en el año siguiente?**

- Backend usado: SQL.
- Consulta generada:

```
SELECT anio, AVG(pct_reactivas_consejeria) AS  
promedio_pct_reactivas_consejeria, SUM(defunciones_vih) AS  
total_defunciones_vih FROM vw_metricas_mensuales_integradas WHERE anio = 2021  
AND pct_reactivas_consejeria > 0 GROUP BY anio ORDER BY anio
```

- Datos proporcionados por la consulta: 1 fila. Columnas: `anio`, `promedio_pct_reactivas_consejeria`, `total_defunciones_vih`.
- Fragmento de salida:

```
2021 | promedio_pct_reactivas_consejeria=12.8 | total_defunciones_vih=440
```

Respuesta del LLM:

El resultado muestra un promedio de porcentaje de pruebas reactivas en 2021 y el total de defunciones por VIH/SIDA en ese mismo año. Sin embargo, no se puede inferir causalidad entre

los cambios en las pruebas reactivas y las variaciones en las defunciones por VIH/SIDA en el siguiente año.

La vista previa muestra un promedio de 12,8% de pruebas reactivas y 440 defunciones.

**Pregunta 19. ¿Qué combinación de indicadores temporales permite identificar periodos con mayor probabilidad de desacople entre menor detección aparente y persistencia de desenlaces graves?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT anio, mes, SUM(pruebas_reactivas) AS pruebas_reactivas,
AVG(cd4_promedio) AS cd4_promedio, COUNT(CASE WHEN total_defunciones > 0 THEN
1 END) AS defunciones, COUNT(CASE WHEN consultas_vih > 0 THEN 1 END) AS
consultas_vih FROM vw_metricas_mensuales_integradas WHERE anio BETWEEN 2020
AND 2023 GROUP BY anio, mes ORDER BY anio, mes
```

- Datos proporcionados por la consulta: 48 filas. Columnas: anio, mes, pruebas\_reactivas, cd4\_promedio, defunciones, consultas\_vih.

- Fragmento de salida:

```
2020 | mes=1 | pruebas_reactivas=3868 | cd4_promedio=0.1999 | defunciones=1 |
consultas_vih=1
2020 | mes=2 | pruebas_reactivas=3868 | cd4_promedio=0.1897 | defunciones=1 |
consultas_vih=1
2020 | mes=3 | pruebas_reactivas=3868 | cd4_promedio=0.1711 | defunciones=1 |
consultas_vih=1
2020 | mes=4 | pruebas_reactivas=3868 | cd4_promedio=NaN | defunciones=1 |
consultas_vih=1
```

Respuesta del LLM:

El resultado muestra una tabla con 24 filas, correspondientes a los meses de 2020 y 2021. Los valores de pruebas reactivas son constantes en ambos años, mientras que los valores de CD4 promedio disminuyen gradualmente a lo largo del tiempo.

Se observa un patrón de desacople entre la detección aparente (pruebas reactivas) y la persistencia de desenlaces graves (defunciones), especialmente en el mes de diciembre de 2020, donde se presentan valores más altos de pruebas reactivas pero también un aumento en las defunciones.

**Pregunta 20. ¿Qué escenarios temporales de recuperación en consultas y detección serían compatibles con una reducción esperada en severidad al diagnóstico y mortalidad por VIH/SIDA?**

- Backend usado: SQL.

- Consulta generada:

```
SELECT * FROM vw_metricas_mensuales_integradas WHERE anio BETWEEN 2020 AND 2023 AND consultas_vih > 0 AND defunciones_vih < total_consultas_vih
```

- Datos proporcionados por la consulta: no hubo tabla devuelta; la ejecución falló.

Respuesta del LLM:

NO\_GENERADA. El campo `interpretacion` quedó como `null`.

## 11. Visualización de resultados de consultas

A partir de los datos obtenidos del agregado de las fuentes de datos, se obtuvieron los siguientes resultados:




Gráfico 21 - Consultas VIH y defunciones VIH por año.

La comparación anual muestra que las consultas VIH comienzan a incrementar a partir de 2020, mientras que las defunciones VIH se mantienen presentes durante todo el periodo.




Gráfico 22 - Pruebas reactivas y consultas VIH por año.

El porcentaje reactivo de pruebas fue mayor en 2022 y disminuyó hacia 2023, mientras que las consultas VIH aumentaron después de 2020.




Gráfico 23 - Indicadores agregados por periodo de análisis.

Por periodo, el bloque postpandemia concentra más consultas VIH y más casos CD4 bajo. La comparación permite observar diferencias de volumen entre periodos, aunque la duración de cada periodo no es idéntica.




Gráfico 24 -Consultas y defunciones VIH por sexo.

Los registros agregados se concentran en la categoría MASCULINO\_HOMBRE. Esto se observa tanto en consultas como en defunciones.




Gráfico 25 - Consultas y defunciones VIH por grupo de edad.

Las consultas VIH se concentran en grupos de edad adultos, especialmente 25\_34, 35\_44 y 45\_54. Las defunciones VIH también se concentran en grupos adultos, con menor volumen en 00\_17 y 65\_MAS.






Gráfico 26 - Consultas de primera vez y subsecuentes por año.

Las consultas subsecuentes superan a las de primera vez entre 2020 y 2023. La diferencia sugiere que el volumen de seguimiento clínico fue mayor que el de nuevos ingresos registrados.




Gráfico 27 - Correlación mensual entre indicadores integrados.

En el mapa de correlación se observa que las variables de atención y laboratorio tienden a moverse juntas: consultas\_vih, muestras\_total y casos\_cd4\_bajo muestran correlaciones positivas altas, lo que indica que cuando aumenta la actividad registrada también aumentan los casos identificados con CD4 bajo.

Por otro lado, el `cd4_promedio` tiene relación negativa con `proporcion_cd4_bajo`, por que cuando crece la proporción de CD4 bajo el promedio de CD4 disminuye. También las defunciones VIH se relacionan de forma más moderada con el resto de indicadores, mientras que `pruebas_reactivas` tiene una relación negativa marcada con `pct_reactivas_consejeria`.

Sin embargo, es importante considerar que las correlaciones pueden existir sin alguna relación real, debido a la procedencia de los datos, las temporalidades, y que se requiere analizar si se puede deber a una causa real el aumento o disminución entre 2 indicadores.

## 12. Conclusiones

### Sobre el proceso de calidad de datos

El proyecto logró pasar de archivos provenientes de fuentes abiertas a salidas comparables por mes, sexo, grupo de edad y periodo y fue posible consultar fuentes clínicas, de laboratorio, de mortalidad y de pruebas reactivas, donde cada fuente aportó indicadores agregados que podían compararse entre sí.

Durante la preparación de los datos se resolvieron problemas de validez, consistencia y duplicidad. Por ejemplo, en HGM se eliminó una edad negativa y se normalizó la variable sexo; en VIH RED se separó sexo/género y se imputaron valores necesarios; y en Defunciones se recalculó edad y se removieron registros fuera del periodo o sin edad calculable.

Además, la deduplicación redujo registros redundantes dentro de cada fuente. Después de la limpieza y la deduplicación, la transformación dejó archivos cargables para PostgreSQL. Estos datos al encontrarse preprocesados, y transformados, resultarán de utilidad para otros proyectos que se tienen planeados.

La integración en SQL permitió crear vistas adecuadas para este proyecto, además de que serán reutilizados en un proyecto de aprendizaje automático. Además, el grafo y el vectorial contribuyen a la consulta de información no limitándose a datos tabulares: NetworkX permitió representar meses, periodos e indicadores, mientras que FAISS permitió recuperar diagnósticos por similitud textual.

### Conclusiones del análisis de negocio

Acorde a lo establecido en la problemática y en el objetivo principal sí fue posible evaluar cambios en consultas, CD4, defunciones y pruebas reactivas, aunque no todas las fuentes se mueven de la misma forma: las consultas VIH aumentan después de 2020, las defunciones VIH presentan poca variación entre 2019 y 2023, y los indicadores de CD4 bajo aumentan después de 2019.

Esto responde la pregunta central del proyecto, porque muestra que analizar una sola fuente no alcanza para interpretar el fenómeno; al comparar las fuentes se observa una lectura más completa sobre atención, severidad, mortalidad y detección.

De forma tentativa se puede concluir que, aunque después de la pandemia se incrementaron los diagnósticos tardíos, las pruebas tuvieron mayor reactividad y las consultas también; las muertes asociadas a VIH/SIDA no lo hicieron. No se busca asumir nada pero de cierta forma muestra que no representa un escenario de complicaciones de salud que terminen en defunción tras este incremento post pandemia.

Las preguntas fueron atendidas por el sistema, pero no todas fueron respondidas con la misma calidad por el LLM. Aquellas relacionadas sobre evolución anual, diferencias por sexo, diferencias por grupo de edad, comportamiento por periodo, CD4, defunciones y pruebas reactivas sí dieron salidas útiles para el análisis del negocio.

En cambio, algunas preguntas del segundo bloque generaron consultas mal formuladas o respuestas insuficientes, especialmente cuando el LLM intentó usar columnas inexistentes, incorrectas o una lógica de predicción que no correspondía con lo disponible. Por eso, el resultado obtenido sí permite contestar la hipótesis general.

El proyecto sí permite observar señales relevantes para la toma de decisiones: las consultas asociadas a VIH se recuperan después de 2020, los casos con CD4 bajo permanecen como un punto crítico, las defunciones no incrementan aunque cambie la actividad de atención, y las pruebas reactivas aportan contexto para revisar detección. Además, los indicadores validan que la epidemia se concentra en `MASCULINO\_HOMBRE` y en grupos adultos, lo que ayuda a orientar preguntas de seguimiento y estrategias de atención.

Así, el proyecto cumple su objetivo principal: construir una base consultable para comparar fuentes y detectar posibles desacoples entre atención clínica, laboratorio, mortalidad y pruebas reactivas.

## Referencias

- [1] M. del P. Angeles, Especificaciones Proyecto Calidad de Datos, documento de clase, Universidad Nacional Autónoma de México, 2026.
- [2] M. del P. Angeles, Syllabus de Preprocesamiento para Ciencia de Datos, documento de clase, Universidad Nacional Autónoma de México, 2026.
- [3] Secretaría de Salud, “Registro de defunciones,” [datos.gob.mx](https://datos.gob.mx), 2025. [En línea]. Disponible en: [https://www.datos.gob.mx/dataset/registro\\_defunciones](https://www.datos.gob.mx/dataset/registro_defunciones). [Consultado: 4-jun-2026].
- [4] Hospital General de México “Dr. Eduardo Liceaga,” “Datos abiertos: Consultas otorgadas,” Hospital General de México, 2026. [En línea]. Disponible en: <https://hgm.salud.gob.mx/interna/trans/datos-abiertos.html>. [Consultado: 4-jun-2026].
- [5] CONAHCYT, “Base de datos,” Red de transmisión y vigilancia de farmacoresistencia del VIH, 2026. [En línea]. Disponible en: <https://salud.conahcyt.mx/vih/datos>. [Consultado: 4-jun-2026].
- [6] Clínicas Especializadas Condesa, “Boletín sobre VIH/sida e ITS de las Clínicas Especializadas Condesa, enero-marzo 2025,” Secretaría de Salud de la Ciudad de México, 2025. [En línea]. Disponible en: <https://condesa.cdmx.gob.mx/boletin/boletin-condesa-ene-mar-2025.pdf>. [Consultado: 4-jun-2026].

- [7] ONUSIDA, “Últimas estadísticas sobre el estado de la epidemia de sida,” ONUSIDA, 2025. [En línea]. Disponible en: <https://www.unaids.org/es/resources/fact-sheet>. [Consultado: 4-jun-2026].
- [8] Centro Nacional para la Prevención y Control del VIH y el sida, “Manual de Procedimientos Estandarizados para la Vigilancia Epidemiológica del VIH - SIDA,” Gobierno de México. [En línea]. Disponible en: <https://www.gob.mx/censida/documentos/manual-de-procedimientos-estandarizados-para-la-vigilancia-epidemiologica-del-vih-sida>. [Consultado: 4-jun-2026].
- [9] Organización Panamericana de la Salud, “CIE-10 en línea, Volumen 1, Español,” OPS/OMS. [En línea]. Disponible en: <https://ais.paho.org/classifications/chapters/>. [Consultado: 4-jun-2026].
- [10] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer y R. Wirth, CRISP-DM 1.0: Step-by-Step Data Mining Guide, SPSS Inc., 2000. [En línea]. Disponible en: <https://public.dhe.ibm.com/software/analytics/spss/documentation/modeler/14.2/es/CRISP-DM.pdf>. [Consultado: 4-jun-2026].
- [11] IBM, “Conceptos básicos de ayuda de CRISP-DM,” IBM Documentation. [En línea]. Disponible en: <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview>. [Consultado: 4-jun-2026].
- [12] P. Lewis et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in Advances in Neural Information Processing Systems, vol. 33, 2020. [En línea]. Disponible en: <https://arxiv.org/abs/2005.11401>. [Consultado: 4-jun-2026].
- [13] IBM, “What Are Data Quality Dimensions?” IBM Think, 2026. [En línea]. Disponible en: <https://www.ibm.com/think/topics/data-quality-dimensions>. [Consultado: 4-jun-2026].
- [14] International Organization for Standardization, ISO 8000-1:2022, Data quality — Part 1: Overview, Geneva, Switzerland: ISO, 2022. [En línea]. Disponible en: <https://www.iso.org/obp/ui/>. [Consultado: 4-jun-2026].
- [15] International Organization for Standardization, ISO 8000-150:2022, Data quality management: Roles and responsibilities, Geneva, Switzerland: ISO, 2022. [En línea]. Disponible en: <https://www.iso.org/standard/80753.html>. [Consultado: 4-jun-2026].
- [16] International Organization for Standardization and International Electrotechnical Commission, ISO/IEC 25012:2008, Software engineering — Software product Quality Requirements and Evaluation (SQuaRE) — Data quality model, Geneva, Switzerland: ISO/IEC, 2008. [En línea]. Disponible en: <https://www.iso.org/obp/ui/>. [Consultado: 4-jun-2026].
- [17] World Health Organization, Data Quality Review: A Toolkit for Facility Data Quality Assessment. Module 1: Framework and Metrics, Geneva, Switzerland: WHO, 2017. [En línea]. Disponible en: <https://iris.who.int/bitstream/handle/10665/259224/9789241512725-eng.pdf>. [Consultado: 4-jun-2026].
- [18] DAMA International, “DAMA-DMBOK: Data Management Body of Knowledge,” DAMA International. [En línea]. Disponible en: <https://dama.org/learning-resources/dama-data-management-body-of-knowledge-dmbok/>. [Consultado: 4-jun-2026].
- [19] UNICEF, Data Quality Framework, New York, NY, USA: UNICEF, 2021. [En línea]. Disponible en: <https://data.unicef.org/wp-content/uploads/2022/01/Data-Quality-Framework.pdf>. [Consultado: 4-jun-2026].
- [20] United Nations Statistics Division, United Nations National Quality Assurance Frameworks Manual for Official Statistics, New York, NY, USA: United Nations, 2019. [En línea]. Disponible en: <https://unstats.un.org/unsd/methodology/dataquality/un-nqaf-manual/>. [Consultado: 4-jun-2026].

- [21] PostgreSQL Global Development Group, “PostgreSQL Documentation,” PostgreSQL, 2026. [En línea]. Disponible en: <https://www.postgresql.org/docs/>. [Consultado: 4-jun-2026].
- [22] NetworkX Developers, “NetworkX documentation,” NetworkX, 2026. [En línea]. Disponible en: <https://networkx.org/documentation/stable/>. [Consultado: 4-jun-2026].
- [23] Meta AI, “Faiss documentation,” Faiss, 2026. [En línea]. Disponible en: <https://faiss.ai/index.html>. [Consultado: 4-jun-2026].