

Universidad Nacional Autónoma de México
Maestría en Ciencia e Ingeniería de la Computación
Preprocesamiento para Ciencia de Datos

Miguel Angel López Sánchez
Avance 1
26 de febrero de 2026

Resumen ejecutivo

Este avance presenta el planteamiento del problema, las variables de interés y las bases de datos seleccionadas para analizar el comportamiento del VIH/SIDA en CDMX antes, durante y después de la pandemia. El objetivo del proyecto es evaluar si la disminución observada durante la pandemia en indicadores asociados a VIH/SIDA puede explicarse por un cambio real en la dinámica del contagio o por efectos relacionados con detección tardía.

Para ello, se propone hasta el momento una estrategia de integración federada a nivel mensual, que permite comparar tres perspectivas complementarias: demanda de atención clínica (consultas), vigilancia y caracterización clínica al diagnóstico (muestras con CD4/carga viral), y resultados finales (defunciones por causa).

En esta primera entrega se cubren, bajo CRISP-DM, las fases:

- 1) Entendimiento del negocio: problemática, objetivo, necesidades, alcance y delimitaciones.
- 2) Entendimiento de los datos, Schema matching y Schema mapping, y variables de valor.

Las actividades de extracción completa, perfilado, limpieza y automatización de procesos se programarán para los siguientes avances.

Problemática

¿La disminución observada durante la pandemia en indicadores asociados a VIH/SIDA en CDMX se puede deber a una reducción de contagios o por falta de detección oportuna (detecciones tardías años más tarde) deducibles a partir de aumento de defunciones o consultas hospitalarias?




Ilustración 1 - Muestra de grafico emitido por Clínica Especializada Condesa

Propuesta de solución

Aplicar la metodología CRISP-DM como mínimo hasta la etapa de calidad de datos. Además se busca una integración se realizará de forma federada

Fase 1. Entendimiento del negocio.

Se establece el objetivo epidemiológico del análisis, se define el salto de tiempo (mes) y se fija una ventana de comparación para la pandemia (marzo 2020 a junio 2021). Se delimitan los resultados de interés: variaciones en demanda de atención, cambios en severidad inmunológica al diagnóstico y cambios en mortalidad por VIH/SIDA.

Fase 2. Entendimiento de los datos.

Se planea aprobar el uso de 3 bases de datos con cobertura de 2019 a 2023 y variables compatibles para su análisis: una base clínica de consultas (HGM), una base de vigilancia por detecciones positivas (CONACYT, ahora SEHCITY) y una base de defunciones por causa (Registro de Defunciones).

Se documenta mpas adelante qué representa cada fuente, sus campos clave, sus limitaciones y su forma de filtrar CDMX:

Fase 3. Preparación de datos.

Se definirá un plan de estandarización según las metodologías del curso para hacer comparables las tres fuentes: normalizar fechas (a mes), codificación de sexo, grupos de edad, y variables de mayor peso para VIH/SIDA y detección tardía. La preparación también incluirá un primer esquema y clasificación por fuentes.

CONTEXTO: VIH/SIDA y variables de interés

El proyecto se enfocará en VIH/SIDA definido por códigos CIE-10 del rango B20 a B24, tanto para la identificación de diagnósticos en consultas como para la identificación de causas en defunciones. El indicador principal propuesto para detección tardía es CD4 menor a 200, complementado con el promedio mensual de CD4. Adicionalmente, se utilizarán sexo y edad como variables demográficas comunes en las tres fuentes, y se trabajará por periodos (pre-pandemia, pandemia, post-pandemia).

Por otra parte, se tendrá en consideración periodos mensuales, teniendo como etapas: prepandemia de inicios de 2019 a febrero 2020, pandemia de marzo 2020 a junio 2021, y post pandemia de julio 2021 a finales 2023

Bases de datos identificadas

Las bases de datos seleccionadas se integran de manera federada para cubrir distintas etapas del fenómeno epidemiológico: atención clínica, vigilancia al diagnóstico y desenlace en mortalidad. Todas las bases se filtrarán a CDMX.

1) VIH_RED_COMPLETA (CONAHCYT).

Contiene información de muestras relacionadas con vigilancia de VIH en CDMX (filtrable por estado), con variables clínicas como cd4_a y carga viral (cv), además de variables demográficas. La cobertura inicia a mediados de 2019 y termina a finales de 2023, por lo que el análisis mensual deberá considerar meses faltantes al inicio o al final del periodo.

- **Cobertura:** mediados de 2019 a finales de 2023.
- **Volumen aproximado:** 12,000 registros.
- **Campos principales:** id_muestra, fecha_toma, sexo, edad, edad_rango, estado, municipio, colonia, cp, seguridad_social, cv, cd4_a, resistencia, cluster_id, grado.

2) CONSULTAS_OTORGADAS_HGM (Hospital General de México).

Contiene registros de consultas otorgadas con fecha completa, sexo y edad, además de especialidad y código diagnóstico. La variable TIPO_CONSULTA permite distinguir primera vez de subsecuente, lo que abre la posibilidad de analizar cambios en patrones de demanda. La procedencia incluye la categoría 'Ciudad de México', lo que habilita el filtrado geográfico.

- **Cobertura:** 2019–2023.
- **Volumen aproximado:** 2,500 registros VIH/SIDA filtrados.
- **Campos principales:** FECHA, TIPO_CONSULTA, PROCEDENCIA, SEXO, EDAD, UNIDAD, ESPECIALIDAD, CODIGO, DESCRIPCION_DIAGNOSTICO.

3) REGISTRO_DEFUNCIONES.

Contiene registros de defunciones con fecha, sexo y variables para derivar edad, además de CAUSA_DEF (código CIE). Se utilizará la entidad de ocurrencia para filtrar a CDMX; como el campo es numérico, se requiere identificar el código que corresponde a la Ciudad de México. El objetivo es construir una serie mensual de defunciones atribuibles a VIH/SIDA (B20 a B24).

- **Cobertura:** por año (archivos separados).
- **Volumen aproximado:** 25,000 registros VIH/SIDA filtrados.
- **Campos principales:** _id, ENT_REGIS, ENT_RESID, CAUSA_DEF, LISTA_MEX, SEXO, EDAD, FECHA_OCURRE, FECHA_NACIM, FECHA_REGIS, FECHA_CERT, ID_INEGI.

La base es heterogénea porque integra fuentes con diferencias en estructura y codificación (sexo como texto o como número, y edad como dato directo o derivado). Es federada porque no une registros a nivel individuo; en su lugar, normaliza variables y se producirán agregados mensuales comparables que se pueden consultar como un esquema global.

Alcance y limitación

El sistema federado se limita a la Ciudad de México. La integración se hará por mes (MM-AAAA) como llave común para permitir: consultas (demanda), vigilancia clínica al diagnóstico (CD4) y mortalidad (defunciones por CIE) en ventanas de tiempo ni muy grandes ni mínimas.

Además se usarán tres periodos: pre-pandemia (enero 2019 a febrero 2020), pandemia (marzo 2020 a junio 2021) y post-pandemia (julio 2021 a diciembre 2023). En el caso de CONAHCYT, se observaron meses faltantes al inicio y/o al final por la cobertura real del dataset.

Modelo canónico

Este modelo se centra en etapas mensuales, delimitado en CDMX:

Atributos para estandarizar:

Fecha: MM-AAAA

Entidad federativa: 'Ciudad de México'

Sexo: categoría estandarizada para comparación (por ejemplo: Hombre, Mujer, No especificado).

Edad_anios: edad en años (directa en HGM y CONAHCYT; se requiere obtener de defunciones por nacimiento y fecha muerte).

VIH_flag: indicador de VIH/SIDA basado en CIE-10 se usa B20–B24 (para HGM y Defunciones).

Detecc_tardia: indicador de detección tardía basado en $cd4_a < 200$ (Etapa SIDA)

Métricas canónicas mensuales (por fuente):

consultas_vih_mes (HGM): conteo de consultas VIH/SIDA por mes.

consultas_primera_vez_mes (HGM): conteo mensual de 'PRIMERA VEZ' cuando aplique.

muestras_mes (CONAHCYT): conteo de muestras por mes.

cd4_promedio_mes (CONAHCYT): promedio mensual de $cd4_a$.

pct_cd4_lt_200_mes (CONAHCYT): porcentaje mensual con $cd4_a < 200$.

muertes_vih_mes (Defunciones): conteo de defunciones por VIH/SIDA (B20–B24) por mes.

Heterogeneidad

Heterogeneidad sintáctica.

- Las fechas están en formato dd/mm/aaaa en las tres fuentes, pero se normalizan a mes (MM-AAAA).
- El campo sexo se codifica distinto: en CONAHCYT aparece como Hombre/Mujer con detalle de identidad Cis/Trans; en HGM como Masculino/Femenino; en defunciones como códigos numéricos.

Heterogeneidad estructural.

- En defunciones, la edad puede no estar lista para análisis en la forma deseada; se propone derivar edad_anios apartir de FECHA_NACIM y FECHA_OCURRENTE cuando sea necesario y documentar la regla.

Heterogeneidad de representación.

- Todas las fuentes son CSV, pero HGM y Defunciones se entregan particionadas por año.

Heterogeneidad semántica.

- La variable de fecha representa cosas diferentes: consulta (HGM), toma de muestra (CONAHCYT) y ocurrencia de defunción (Defunciones). No se confunden; se usan como fecha base de su respectiva métrica y luego se comparan por el mes calendario.
- La entidad federativa ‘Ciudad de México’ aparece como texto en HGM y CONAHCYT, y como código numérico en defunciones; se resuelve con un catálogo de códigos de entidad.

Schema matching (correspondencias hacia el modelo canónico)

El schema matching identifica qué columnas locales corresponden a qué atributos canónicos. La siguiente tabla resume las correspondencias principales.

Atributo canónico	HGM (consultas)	CONAHCYT (muestras)	Defunciones	Notas
fecha_base	FECHA	fecha_toma	FECHA_OCURRE	Se usa para derivar el mes; representa eventos distintos por fuente.
mes (MM-AAAA)	Derivado de FECHA	Derivado de fecha_toma	Derivado de FECHA_OCURRE	Moneda de federación y comparación.
sexo_local	SEXO	sexo	SEXO	Requiere mapeo a sexo_std.
sexo_std	Derivado de SEXO	Derivado de sexo	Derivado de SEXO	Hombre/Mujer/No especificado; preservar detalle Cis/Trans en identidad_genero (opcional).
edad_anios	EDAD	edad	EDAD o derivado	En defunciones puede requerir derivación con FECHA_NACIM.
grupo_edad_5	Derivado de EDAD	Derivado de edad	Derivado de edad_anios	Bandas de 5 años.
cd4_a	No aplica	cd4_a	No aplica	Solo CONAHCYT.
late_flag (cd4<200)	No aplica	Derivado de cd4_a	No aplica	Indicador de detección tardía.
cie_vih	CODIGO	No aplica	CAUSA_DEF	Se filtra por B20–B24; incluye subcódigos.
vih_flag	Derivado de CODIGO	No aplica	Derivado de CAUSA_DEF	Indicador de VIH/SIDA en HGM y Defunciones.
cdmx_flag	PROCEDENCIA	estado	ENT_* (código entidad)	En defunciones se define con catálogo; en HGM y CONAHCYT es texto.

Schema mapping (transformaciones al esquema canónico)

En este schema mapping se especifica la transformación datos locales en instancias compatibles con el esquema canónico y el esquema federado. Se propone el siguiente mapeo:

Regla transformación /	Fuente	Entrada	Salida canónica	Detalle de la regla
Derivar mes	HGM	FECHA (dd/mm/aaaa)	mes (MM-AAAA)	Convertir fecha a mes y año; formatear como MM-AAAA.
Derivar mes	CONAHCYT	fecha_toma	mes (MM-AAAA)	Convertir fecha_toma a mes.
Derivar mes	Defunciones	FECHA_OCURRE	mes (MM-AAAA)	Convertir FECHA_OCURRE a mes.
Estandarizar sexo	HGM	SEXO (Masculino/Femenino)	sexo	Masculino → Hombre; Femenino → Mujer; otros → No especificado.
Estandarizar sexo	CONAHCYT	sexo	sexo	Mapear a Hombre/Mujer; No conservar identidades transgenero en esta etapa para no invalidar.
Estandarizar sexo	Defunciones	SEXO (1/2 u otros)	sexo	Tabla: 1 → Hombre; 2 → Mujer; otros → No especificado (a validar).
Derivar edad_años	Defunciones	FECHA_NACIM + FECHA_OCURRE	edad_años	Edad = años completos entre nacimiento y ocurrencia (si se requiere).
Grupo de edad 5 en 5	Todas	edad_años	grupo_edad_5	Asignar a bandas quinquenales; 85+ como último grupo.
VIH/SIDA en HGM	HGM	CODIGO	vih_flag	vih_flag=1 si el código inicia con B20, B21, B22, B23 o B24 (incluye subcódigos).
VIH/SIDA en Defunciones	Defunciones	CAUSA_DEF	vih_flag	vih_flag=1 si CAUSA_DEF inicia con B20–B24.
Detección tardía	CONAHCYT	cd4_a	detecc_tard	late_flag=1 si cd4_a < 200.
Filtrar CDMX	HGM/CONAHCYT	PROCEDENCIA / estado	cdmx_flag	Conservar registros con 'Ciudad de México' (normalizando mayúsculas/acentos).
Filtrar CDMX	Defunciones	ENT_* (código entidad)	cdmx_flag	Identificar el código numérico de CDMX mediante catálogo y filtrar por entidad de ocurrencia.

Referencias

Registro de Defunciones: https://www.datos.gob.mx/dataset/registro_defunciones

VIH CONAHCYT: <https://salud.conahcyt.mx/vih/datos>

Hospital General de México — Datos abiertos: <https://hgm.salud.gob.mx/interna/trans/datos-abiertos.html>